

Visuelle Artenklassifizierung durch maschinelles Lernen

Eine systematische Literaturrecherche

Seminararbeit

vorgelegt am 9. Februar 2018

Fakultät Wirtschaft

Studiengang Wirtschaftsinformatik

Kurs WWI2015F

von

DENNIS ADELER
TOBIAS EBERLE
ANDREAS FRÖLICH
MARTHA KLIMEK
MANUEL KOPITTKER
LISA MARTINY
MIKE NOLDEN

DHBW Stuttgart:

Prof. Dr. Kai Holzweißig

Inhaltsverzeichnis

Abkürzungsverzeichnis	III
Abbildungsverzeichnis	IV
Tabellenverzeichnis	V
1 Einleitung	1
1.1 Motivation und Problemstellung	1
1.2 Zielsetzung und weiteres Vorgehen	2
2 Forschungsmethodik	4
2.1 Notwendigkeit und Ablauf	4
2.2 Forschungsfragen	5
2.3 Such- und Auswahlstrategie	6
2.4 Datenextraktion	8
3 Auswertung	10
3.1 Metadaten	10
3.2 Bildakquise	13
3.3 Pre-Processing	16
3.4 Merkmalsextraktion	17
3.4.1 Betrachtungsobjekte	17
3.4.2 Organe	18
3.4.3 Eigenschaften	19
3.4.4 Deskriptoren	21
3.5 Klassifikation	24
3.5.1 Definition verschiedener Klassifikatoren	25
3.5.2 Verteilung der Klassifikatoren	29
4 Ergebnisse	37
4.1 Kritische Reflexion	37
4.2 Hauptergebnisse	38
Anhang	40
Quellenverzeichnisse	49
Ehrenwörtliche Erklärung	53

Abkürzungsverzeichnis

ACM	Association for Computing Machinery
ANN	Artificial Neural Network
BLS	Branch Length Similarity
CNN	Convolutional Neural Network
DHBW	Duale Hochschule Baden-Württemberg
ELM	Extreme Learning Machine
GLCM	Grey Level Co-occurrence Matrix
IEEE	Institute of Electrical and Electronics Engineers
LBP	Local Binary Pattern
LDA	Linear Discriminant Analysis
MAP	Mean Average Precision
MLP	Multilayer-Perceptron
NN	Nearest Neighbour
PCA	Principal Component Analysis
PNN	Probabilistic Neural Network
RF	Random Forest
SIFT	Scale Invariant Feature Transform
SLR	Systematische Literaturrecherche
SMNK	Staatliches Museum für Naturkunde Karlsruhe
SMSD	Simple and Morphological Shape Descriptors
SVM	Support Vector Machine

Abbildungsverzeichnis

1	Auswertung der Durchführungsorte der Forschung nach Land	11
2	Auswertung der Durchführungsorte der Forschung nach Kontinent	12
3	Auswertung der Hintergrundbeschaffenheit.	15
4	Auswertung des Zustands der Objekte.	15
5	Verteilung der Betrachtungsobjekte.	18
6	Verteilung der betrachteten Organe.	19
7	Verteilung der betrachteten Eigenschaften.	20
8	Verteilung der Deskriptoren.	22
9	Einfaches neuronales Netz (Multi-Layer-Perceptron)	26
10	Schematische Abbildung eines CNN	27
11	Unterschied zwischen der Linear Discriminant Analysis und der Principal Component Analysis	28
12	Ein einfacher Entscheidungsbaum	29
13	Precision-Recall Graph	30
14	Verteilung der Klassifikatoren.	33
15	Verteilung der Klassifikator innerhalb der neuronalen Netze.	34
16	Minimum, Mittelwert und Maximum der Messgenauigkeit der Klassifikatoren. . .	34
17	Minimum, Mittelwert und Maximum der Messgenauigkeit der Klassifikatoren. Vergleich zwischen Accuracy und MAP.	35
18	Vergleich der Mittelwerte der verschiedenen, analysierten Klassifikatoren.	36

Tabellenverzeichnis

2	Auswertung der Veröffentlichungsjahre der Publikationen.	12
1	Auswertung der Fachgebiete der Autoren und der veröffentlichenden wissenschaftlichen Bibliotheken.	13
3	Auswertung der Datenset-Größe.	14
4	Auswertung der Bildquellen.	14
5	Auswertung der Klassen-Größe.	16
6	Auswertung des Verhältnisses von Datenset-Größe zur Klassenanzahl.	16
7	Durchschnittliche Klassifikationsgenauigkeit im Bezug auf die betrachteten Organe.	19
8	Kombination verschiedener Eigenschaften.	21
9	Durchschnittliche Genauigkeit des Klassifikators nach Anzahl der betrachteten Eigenschaften.	21
10	Durchschnittliche Genauigkeit des Klassifikators nach kombinierten Eigenschaften.	21
11	Quellen Startset.	42

1 Einleitung

Das, im fünften und sechsten Semester an der Dualen Hochschule Baden-Württemberg (DHBW) Stuttgart stattfindende, Integrationsseminar beschäftigt sich mit der theoretischen Aufarbeitung eines aktuellen Themas aus der Praxis der Wirtschaftsinformatik. Das Ziel des fünften Semesters ist es, alle notwendigen Vorarbeiten für die Umsetzung des Projekts im sechsten Semester zu erledigen. Diese Vorbereitung umfasst zum einen ein gesondertes Projektplanungsdokument zur Strukturierung des weiteren Projektvorgehens, als auch, als Basis dafür, die Aufarbeitung des aktuellen Stands der Wissenschaft in Form dieser Literaturrecherche. Zu Beginn dieser Ausarbeitung soll dabei zuerst auf die Motivation und die Problemstellung, als auch auf die Zielsetzung und das weitere Vorgehen dieser wissenschaftlichen Ausarbeitung eingegangen werden.

1.1 Motivation und Problemstellung

Das Staatliches Museum für Naturkunde Karlsruhe (SMNK) beschäftigt sich als Projektpartner schon seit mehreren Jahren mit dem permanenten Wandel der Schmetterlingsfauna in Baden-Württemberg. Dafür werden Schmetterlingsbeobachtungen in der am SMNK befindlichen Landesdatenbank (Access-Datenbank InsectIS) dokumentiert. Die so erstellten Verbreitungskarten sind online für jedermann abrufbar, um sich über den aktuellen Stand in Baden-Württemberg zu informieren. Gesellschaftliche Relevanz erhält diese Thematik dadurch, dass die Landesdatenbank auch als Grundlage für die Erstellung und Aktualisierung Roter Listen und Artenschutzprogrammen dient.

Durch die Zusammenarbeit mit der DHBW erhofft sich das SMNK die Optimierung der Meldungsoptionen für die benötigten Schmetterlingsbeobachtungen und dadurch einen Anstieg der dringend benötigten Beobachtungsmeldungen. Deswegen wird in Zusammenarbeit mit Projektteam Eins der DHBW eine mobile Applikation für die komfortablere Meldung von Schmetterlingsbeobachtungen entwickelt. Das stellt das SMNK aber anschließend vor die Herausforderung, die gestiegene Anzahl an eingereichten Beiträgen, wie bisher, manuell durch Experten verifizieren zu lassen. Projektteam Zwei beschäftigt sich daher mit der Möglichkeit der automatischen Überprüfung der Schmetterlingsbeobachtungen anhand der eingereichten Bilder mit Hilfe von Techniken des maschinellen Lernens. In Abstimmung mit dem SMNK wurde dabei folgender Projektauftrag konkretisiert: *Im Zuge des Projekts soll die Entwicklung einer prototypischen Klassifizierungskomponente für Schmetterlingsarten auf Basis von Techniken des maschinellen Lernens stattfinden, die in den Funktionsumfang der mobilen Meldeapplikation des Projektteam Eins integriert werden soll.*

Abgeleitet aus der Komplexität des Arbeitsauftrags ergibt sich für die Zwecke dieser Literaturrecherche die Frage nach dem aktuellen Stand der Wissenschaft bezüglich der Entwicklung solcher Komponenten für ähnliche Anwendungszwecke. Als Problemstellung formuliert, könnte gefragt

werden: *Welche Komponenten, Schritte und Technologien werden für die Klassifizierung eines Bildes benötigt, welche konkreten Ansätze wurden dafür in der Forschung evaluiert und welche dieser Ansätze können für die Verwendung bei der Erstellung der vorgestellten Klassifizierungskomponente gewählt werden?*

1.2 Zielsetzung und weiteres Vorgehen

Das Ziel dieser Literaturrecherche ist es entsprechend der zuvor definierten Problemstellung grundsätzliche Bestandteile einer solchen Klassifizierungskomponente zu identifizieren, die Vor- und Nachteile in der Forschung verfolgter Ansätze zu evaluieren und basierend auf dem gewonnen Überblick Ansätze zu identifizieren, die bei der Erstellung der Klassifizierungskomponente verwendet werden können.

Für die Erarbeitung dieses Überblicks über den aktuellen Stand der Forschung, kommt wie für die meisten anderen Forschungsprojekte eine Literaturrecherche in Frage.¹ Bei dieser Methode handelt es sich um den Prozess des Identifizierens, Evaluierens und Interpretierens der verfügbaren Literatur im Bezug auf eine Forschungsfrage oder ein bestimmtes Forschungsgebiet. Aus den untersuchten Primärquellen ergibt sich durch methodische Transformation eine Sekundärstudie.² Am Ende einer solchen Sekundärstudie steht als Ergebnis ein Überblick über die Errungenschaften, die unterschiedlichen Ansätze und die ausstehenden Forschungsfragen auf dem Forschungsgebiet.³ Differenzen im Bezug auf die Methodik solcher Literaturrecherchen bestehen hauptsächlich hinsichtlich der Systematik. Eine Narrative Literaturrecherche bewegt sich sehr stark im subjektiven Bereich der qualitativen Forschung. Eine Systematische Literaturrecherche (SLR) hingegen zielt darauf ab, Hypothesen auf Basis der untersuchten Objekte, mit Hilfe eines vorher definierten Protokolls, zu überprüfen. Dadurch soll eine höchst mögliche Objektivität erzeugt werden.⁴ Aus Gründen der Nachvollziehbarkeit und Objektivität der Analyse der Primärquellen soll für die Zwecke dieser Arbeit deshalb auf eine SLR zurückgegriffen werden.

Grundsätzlich ist diese Arbeit, auch bedingt durch die gewählte Forschungsmethodik, als theoretischer Hintergrund für die weitere wissenschaftliche Ausarbeitung im sechsten Semester zu verstehen. Um der Zielsetzung und dieser Einordnung in das gesamte Projekt gerecht zu werden, wird deshalb folgende Struktur gewählt:

Nach dieser Einleitung folgt mit Kapitel 2 eine genaue Erklärung der Forschungsmethodik und eine Betrachtung des projektspezifischen Vorgehens. In Kapitel 3 werden daraufhin die Ergebnisse der zuvor besprochenen SLR präsentiert. Als Basis dafür wird im ersten Unterkapitel (3.1) zuerst eine Auswertung der Metadaten der untersuchten Quellen stattfinden. Im Anschluss daran werden die Ergebnisse den Prozessschritten der Bildklassifizierung entsprechend⁵ in die Unterkapitel

¹Vgl. Pautasso 2013, S.1

²Vgl. Kitchenham 2004, S. 1

³Vgl. Pautasso 2013, S.3

⁴Vgl. Pautasso 2013, S.2

⁵Vgl. Wäldchen/Mäder 2017, S.510

Bildakquise (3.2), Pre-Processing (3.3), Merkmalsextraktion (3.4) und Klassifikation (3.5) unterteilt: In Unterkapitel 3.2 sollen entsprechend verschiedene Ansätze zur Bereitstellung von Bildern des zu klassifizierenden Objekts als Bedingung für die Ausführung der weiteren Klassifizierungsschritte diskutiert werden.⁶ Unterkapitel 3.3 wird sich mit dem sogenannten Pre-Processing, also dem Optimieren der Bilddaten, sodass unerwünschte Verzerrungen unterdrückt und für die weitere Verarbeitung relevante Bildmerkmale hervorgehoben werden⁷, beschäftigen. Inhaltlich wird sich das folgedende Unterkapitel 3.4 mit der Merkmalsextraktion, also mit dem Messen von geometrischen oder anderen möglicherweise segmentierten, bedeutungsvollen Bereichen im Bild⁸, beschäftigen. Die eigentliche Klassifizierung des Bildes, also das Bilden eines Merkmalsvektors aus allen extrahierten Merkmalen und dessen Klassifizierung⁹, wird in Unterkapitel 3.5 thematisiert. Zum Schluss sollen dann in Kapitel 4 die für das weitere Vorgehen relevanten Ergebnisse der Literaturrecherche zusammengefasst, aufbereitet und diskutiert werden, sodass sie bei der Entwicklung des Prototypen im nächsten Semester mit einfließen können.

⁶Vgl. Wäldchen/Mäder 2017, S.510

⁷Vgl. Wäldchen/Mäder 2017, S.510

⁸Vgl. Wäldchen/Mäder 2017, S.510

⁹Vgl. Wäldchen/Mäder 2017, S.510

2 Forschungsmethodik

Wie bereits in Kapitel 1.2 angeschnitten, soll im Laufe dieser Arbeit eine SLR durchgeführt werden. Das folgende Kapitel bietet einen detaillierten Überblick über die konkrete Vorgehensweise. Dazu soll zuerst auf die Methodik und ihre Notwendigkeit und im weiteren Verlauf auf ihre elementaren Bestandteile eingegangen werden.

2.1 Notwendigkeit und Ablauf

Zunächst ist es wichtig zu verstehen warum sich im Vorfeld des Projekts mit der Durchführung einer solchen Analyse beschäftigt werden muss. Grundsätzlich kann Forschung den Ansprüchen der Wissenschaft nur dann genügen, wenn vorher alle existierenden Informationen zu einem Phänomen auf eine objektive und nachvollziehbare Art und Weise zusammengetragen wurden.¹⁰ Aufgrund der kontinuierlich ansteigenden Geschwindigkeit bei der Veröffentlichung von wissenschaftlichen Publikationen, ist die Literaturrecherche heute ein notwendiges Mittel, um sich einen Überblick über ein Themengebiet zu verschaffen und relevante Publikationen als Basis für die eigene Arbeit ausfindig zu machen.¹¹ Die SLR kann also dazu genutzt werden, das benötigte Fundament für die angemessene Positionierung der weiteren Forschung und der dazu gehörigen wissenschaftlichen Ausarbeitung zu legen.¹²

Methodisch sind Literaturrecherchen in der qualitativen Forschung verankert, in der offene Forschungsfragen sehr detailliert mit in diesem Fall teils strukturierten Datenerhebungsmethoden untersucht werden. Die erhobenen qualitativen Daten werden dabei interpretativ ausgewertet.¹³ Präziser gefasst lässt sich die Literaturrecherche als Werkzeug zur Erschaffung von neuem Wissen durch die Synthese von bestehendem Wissen beschreiben.¹⁴ Dabei ergeben sich bezogen auf die Synthese von Wissen grundsätzlich zwei Interpretationsmöglichkeiten und somit zwei unterschiedliche Ansätze zur Durchführung einer Literaturrecherche:

1. Deskriptive Literaturrecherchen fokussieren sich auf die Beschreibung der Methodik, der Ergebnisse und der Interpretation der analysierten Publikation.
2. Integrative Literaturrecherchen versuchen hingegen gemeinsame Ideen und Konzepte des untersuchten Materials zu identifizieren.¹⁵

In diesem Fall wird aufgrund der Zielsetzung der Arbeit für die Durchführung eine integrative Literaturrecherche genutzt. Der Zielsetzung entsprechend ist die vollständige Abbildung des

¹⁰Vgl. Kitchenham 2004, S.3

¹¹Vgl. Pautasso 2013, S.1

¹²Vgl. Kitchenham 2004, S.2

¹³Vgl. dazu ausführlich Döring/Bortz 2016, S.184

¹⁴Vgl. Pautasso 2013, S.1

¹⁵Vgl. Pautasso 2013, S.2

Standes der Forschung nicht Gegenstand dieser Arbeit. Vielmehr liegt der Fokus auf der Betrachtung und Evaluation der als erfolgversprechend betrachteten Konzepte als Grundlage für die Erstellung eines eigenen Konzepts und die Diskussion ihrer Adaption im Bezug auf die weitere Forschung.

Damit eine Literaturanalyse auch eine wissenschaftliche Existenzberechtigung aufweist, ist es zwingend erforderlich, dass sie professionell und vor allem strukturiert durchgeführt wird.¹⁶ Der dadurch motivierten Entscheidung zur Durchführung einer SLR entsprechend, wird im Folgenden die Systematik einer solchen Literaturrecherche zu veranschaulicht.

Generell besteht eine SLR aus drei Phasen: Planungsphase, Durchführungsphase und Berichterstattungsphase.¹⁷ Zu beachten ist dabei, dass es sich bei diesem Phasenmodell um einen iterativen Ablauf handelt. Viele Aktivitäten werden zwar bereits durch die Planungsphase angestoßen, können sich im Laufe der Durchführungsphase aber noch verändern.¹⁸ Nachfolgend aufgelistet sind die Zielsetzungen der einzelnen Phasen: Die Planungsphase umfasst die Identifikation der Notwendigkeit einer Literaturanalyse und das Erstellen des Analysedokuments.¹⁹ Dieses spezifiziert die zur Durchführung der SLR genutzten Methoden und geht dabei auf die zu beantwortenden Forschungsfragen, die Suchstrategie für Primärquellen, die Auswahlkriterien für die Aufnahme dieser, die Strategie zur Extraktion der Daten, sowie auf die Strategie zur Synthese der Daten ein.²⁰ Als nächsten Schritt umfasst die Durchführungsphase die Auswahl relevanter Primärquellen auf Basis der Suchstrategie und den definierten Auswahlkriterien, die Evaluation der Qualität, die Extraktion, als auch die Synthese der Daten.²¹ Die Berichterstattung in Form der Kommunikation der Ergebnisse der SLR durch eine wissenschaftliche Arbeit wird als wichtiger Schritt und eigene abschließende Phase spezifiziert.²²

Die Ergebnisse der Planungsphase sind im übergeordneten Kapitel 2 zu finden. Dem entsprechend folgt die weitere Struktur dieses Kapitels auch den eben beschriebenen, inhaltlichen Schwerpunkten des Analysedokuments. Die Ergebnisse der Durchführungsphase als Erkenntnisse dieser Arbeit lassen sich im weiteren Verlauf in Kapitel 3 und abschließend in Kapitel 4 verorten.

2.2 Forschungsfragen

Der zu Beginn dieses Kapitels erwähnten Einordnung der SLR in die qualitative Forschung entsprechend bildet die Definition der Forschungsfragen den Ausgangspunkt für das weitere Vorgehen, indem die Datenerhebung auf Basis nicht-standardisierter Erhebungsinstrumente durch die hier definierten Forschungsfragen geleitet wird.²³ Typischerweise stellen sich SLR im Bereich

¹⁶Vgl. Pautasso 2013, S.1

¹⁷Vgl. Kitchenham 2004, S.3

¹⁸Vgl. Kitchenham 2004, S.5

¹⁹Vgl. Kitchenham 2004, S.3

²⁰Vgl. Kitchenham 2004, S.4

²¹Vgl. Kitchenham 2004, S.3

²²Vgl. Kitchenham 2004, S.22 f

²³Vgl. dazu ausführlich Döring/Bortz 2016, S.222

der Informatik, insbesondere in der Softwareentwicklung, Fragen, die sich mit den Auswirkungen oder der Adaption einer Technologie beschäftigen.²⁴ Wird die SLR, wie in dieser Arbeit, jedoch als Gerüst für weitere Forschung genutzt, so empfiehlt es sich, Forschungsfragen zu definieren, die sich hauptsächlich mit den Interessen der durchführenden Personen überschneiden. Deshalb werden Forschungsfragen gewählt, die weitere Forschungsfelder identifizieren oder, wie in diesem Fall, den Umfang zukünftiger Forschungsaktivitäten definieren.²⁵ Entsprechend den bereits diskutierten Prozessschritten der Bildklassifizierung werden für die Zwecke dieser SLR die folgenden Forschungsfragen definiert:

1. Was für eine Verteilung der Metadaten ergibt sich über alle untersuchten Publikationen hinweg? (Diese Frage ist für die Beurteilung der Aussagekraft unserer Literaturrecherche relevant.)
2. Wie viele Arten wurden auf Basis wie vieler Bilder betrachtet, wie wurden diese Bilder erfasst und in welchem Kontext wurden sie aufgenommen?
3. Welche Merkmale wurden insbesondere im Bezug auf die Erkennung von Schmetterlingen extrahiert und welche Techniken wurden dabei verwendet?
4. Welche Klassifikatoren kamen zum Einsatz und welche liefern die beste Genauigkeiten bei der Artenerkennung?

Zu beachten ist, dass die soeben definierten Forschungsfragen zwar steuern, welche Daten im Zuge der SLR aus den untersuchten Primärstudien extrahiert, analysiert und synthetisiert werden. Sie haben aber keinen Einfluss auf die Suche und Auswahl des eigentlichen Datenmaterials. Diese Vorgehensweise wird im Zuge der Such- und Auswahlstrategie festgelegt und soll im Folgenden in Unterkapitel 2.3 diskutiert werden.

2.3 Such- und Auswahlstrategie

Eine Entwicklung im Bezug auf SLR ist es, Informationen über die Suche nach den analysierten Publikationen zu inkludieren, um die Ergebnisse der Arbeit nachvollziehbarer zu gestalten.²⁶ Dementsprechend wird im Folgenden die Suchstrategie näher erläutert. Das Ziel einer SLR ist es, mit Hilfe einer objektiven und strengen Suchstrategie so viele relevante Primärquelle wie möglich zu finden. Dieser strenge Suchprozess ist einer der Faktoren, der diese Art der Literaturrecherche von traditionellen Literaturrecherchen unterscheidet.²⁷

Für die Zwecke dieser Arbeit wird eine Kombination aus rückwärts und vorwärts gewandtem Snowballing genutzt. Rückwärts gewandtes Snowballing heißt, die referenzierten Publikationen

²⁴Vgl. Kitchenham 2004, S.5

²⁵Vgl. Kitchenham 2004, S.6

²⁶Vgl. Pautasso 2013, S.3

²⁷Vgl. Kitchenham 2004, S. 7

jeder Primärquelle werden rekursiv als Kandidaten für die Literaturrecherche betrachtet.²⁸ Vorwärts gewandtes Snowballing heißt umgekehrt, Publikationen, die bereits inkludierte Publikationen zitieren, werden ebenso rekursiv als Kandidaten für die Literaturanalyse betrachtet. Gängige Praxis für die Bewertung der Qualität solcher Quellen ist es, die Anzahl an Zitationen heran zu ziehen.²⁹ Der Vorteil dieser kombinierten Methodik liegt darin, dass sie einen relativ kompletten Überblick über die relevante Literatur ermöglicht, ohne sich dabei auf bestimmte Vorgehensweisen in den Primärquellen, eine Reihe von Zeitschriften und Konferenzen oder eine geografische Region zu beschränken.³⁰

Die Qualität des Ergebnisses der gesamten Forschungsmethodik hängt von dem gewählten Startset ab. Dementsprechend besteht an Publikationen aus diesem Startset die Anforderung eine hohe Relevanz bezüglich des untersuchten Forschungsgebiets aufzuweisen.³¹ Nur so kann die Qualität der als Kandidaten behandelten Quellen über den Prozess der Suche garantiert werden. Eine manuelle Suche über Google Scholar ist eine erprobte Vorgehensweise zum Erstellen eines solchen Startsets. Vorteilhaft ist hierbei, dass vermieden wird, sich von Beginn an auf bestimmte Herausgeber zu beschränken.³² Zur Suche geeigneter Quellen wird folgendes Muster an Schlagwörtern verwendet: S1 und (S3 oder S4 oder S5) oder S2 und (S3 oder S4 oder S5 oder S6). Die Variablen stehen jeweils für eine Gruppe von Suchworten, die folgendermaßen definiert wird: S1 (,butterfly‘ oder ,lepidoptera‘ oder ,moth‘ oder ,insect‘ oder ,plant‘ oder ,leaf‘), S2 (,butterfly image‘ oder ,lepidoptera image‘ oder ,moth image‘ oder ,insect image‘ oder ,plant image‘ oder ,leaf image‘), S3 (,recognition‘ oder ,recognize‘ oder ,recognizing‘ oder ,recognized‘), S4 (,identification‘ oder ,identify‘ oder ,identifying‘ oder ,identified‘), S5 (,classification‘ oder ,classify‘ oder ,classifying‘ oder ,classified‘) und S6 (,image processing‘ oder ,computer vision‘). Nach dieser Schlagwortsuche werden die Quelle auf den Bezug zur Problemstellung untersucht und die Qualität der Quelle auf Basis der von Google Scholar angezeigten Anzahl der Zitationen eingeschätzt.

Da die frühe Definition strikter Ausschlusskriterien im Bezug auf die Quellenauswahl wichtig ist um den Fokus der Literaturrecherche zu setzen und somit einen kritischen Erfolgsfaktor für den Ausgang einer Literaturrecherche darstellt,³³ werden die für die SLR definierten Auswahlkriterien nicht nur im weiteren Verlauf der Forschungsmethodik, sondern auch schon bei der Auswahl des Startsets berücksichtigt. Aus Gründen der Nachvollziehbarkeit sind sie deshalb im Folgenden dargestellt:

Die Quelle muss in einer der acht folgenden wissenschaftlichen Bibliotheken veröffentlicht worden sein: Association for Computing Machinery (ACM) Digital Library, CiteSeerX, Elsevier ScienceDirect, Institute of Electrical and Electronics Engineers (IEEE) Xplore Digital Library, ResearchGate, Springer, Taylor & Francis, Wiley Online Library. Die Beschränkung der Kandidaten für die Aufnahme in die SLR auf diese acht renommierten wissenschaftlichen Bibliotheken ist vor

²⁸Vgl. Wäldchen/Mäder 2017, S.512

²⁹Vgl. Wäldchen/Mäder 2017, S.512

³⁰Vgl. Wäldchen/Mäder 2017, S.511

³¹Vgl. Wäldchen/Mäder 2017, S.511

³²Vgl. Wäldchen/Mäder 2017, S.512

³³Vgl. Pautasso 2013, S.1

allem vor dem Hintergrund der Qualitätssicherung im Bezug auf die Forschungsansätze der untersuchten Quellen zu verstehen. Mit der Entscheidung zur Nutzung einer relativ großen Anzahl an Bibliotheken, soll die in Literaturrecherchen angestrebte Diversifizierung der Datenquellen³⁴ jedoch nicht zu sehr eingeschränkt werden.

Quellen mit Bezug auf die Erkennung von Schmetterlingsarten dürfen nicht älter als 15 Jahre, Quellen mit Bezug auf die Erkennung anderer Objekte nicht älter als zehn Jahre sein. Diese Anforderung an die zu untersuchenden Quellen ergibt sich angesichts der fortschreitenden Beschleunigung der Veröffentlichung wissenschaftlicher Publikationen.³⁵ Quellen, die älter als 15 Jahre alt sind, verlieren aufgrund des rasanten wissenschaftlichen Fortschritts ihre Relevanz im Bezug auf ihren Forschungsansatz. Deshalb sollen in der Literaturrecherche vor allem jüngere Primärquellen betrachtet werden. Die geringeren Anforderungen an Primärquellen, die sich mit der Erkennung von Schmetterlingsarten befassen, ergeben sich aus der geringen Verbreitung solcher Studien im Vergleich zu der Erkennung anderer Objekte.

Bei den im Laufe dieser SLR untersuchten Primärquellen muss es sich zwangsläufig um richtige Publikationen handeln. Sowohl informelle Beiträge zu Workshops, als auch Notizen zu noch nicht veröffentlichten Arbeiten werden nicht betrachtet. Die Definition eines solchen Kriteriums ist gängige Praxis und wird damit begründet, dass so nur geprüfte Quellen mit hoher Qualität als Kandidaten für die Literaturanalyse in Frage kommen.³⁶

Das vierte und letzte Kriterium bezieht sich auf die Länge der untersuchten Publikationen. Quellen müssen eine Mindestlänge von vier Seiten aufweisen um in die Literaturrecherche aufgenommen zu werden. Bei Quellen mit geringerem Umfang wird davon ausgegangen, dass diese sich aufgrund der Limitation nur oberflächlich und nicht in genügender Tiefe mit der Forschungsthematik auseinandersetzen.

Nach Durchführung des beschriebenen Vorgehens umfasst das Startset, Anhang 1, entsprechend insgesamt zehn Quellen. Dabei werden anders als bei der Betrachtung der Kandidaten für die Literaturrecherche nicht nur Primär-, sondern auch Sekundärquellen, welche sich mit ähnlichen Themen befassen, in Betracht gezogen. Das stellt gängige Praxis dar, um die Anzahl der Kandidaten für die Literaturrecherche zu erhöhen.³⁷ Auf Basis dieses Startsets werden der Such- und Auswahlstrategie entsprechend nach folgendem Datenextraktionstemplate Informationen zu weiteren 81 Primärquellen gewonnen.

2.4 Datenextraktion

Wie bereits in Kapitel 2.2 beschrieben, orientiert sich die Extraktion der Daten an den zuvor definierten Forschungsfragen. Um die erste Forschungsfrage zu beantworten, werden zuerst die

³⁴Vgl. Pautasso 2013, S.2

³⁵Vgl. Pautasso 2013, S.3

³⁶Vgl. Wäldchen/Mäder 2017, S.512

³⁷Vgl. Pautasso 2013, S.1

Metadaten der Primärquellen extrahiert. Für die übrigen Forschungsfragen wird das Vorgehen des in der Primärquelle beschriebenen Ansatzes zur Klassifizierung von Objekten entsprechend den Prozessschritten der Bildklassifizierung betrachtet: Bildakquise, Preprocessing, Merkmalsextraktion und Klassifikation.³⁸ Präziser kann das Extraktionstemplate als Basis für die Ergebnisse dieser Arbeit anhand folgender Aufteilung beschrieben werden:

Zur Auswertung der Metadaten werden für jede Quelle die Autoren, der wissenschaftliche Hintergrund, die Herkunft, das Veröffentlichungsjahr, der Publikationstyp und die wissenschaftliche Bibliothek, in der die Arbeit publiziert wurde, dokumentiert. Bezogen auf die Bildakquise, wird der Betrachtungsgegenstand, die Anzahl der Klassen, die Anzahl der Trainings- und Testdaten, die Bildquelle und der Bildhintergrund dokumentiert. Für den Prozessschritt der Merkmalsextraktion wird die Preprocessing Methode, das betrachtete Organ, das extrahierte Merkmal, sowie der konkrete Deskriptor extrahiert. Bezogen auf die Klassifikation wird zum einen der genutzte Klassifikator und zum anderen die bei den durchgeführten Tests maximal erreichte Genauigkeit dokumentiert. Auf Basis dieser Datenlage finden die weiteren Auswertungen innerhalb dieser Ausarbeitung statt.

³⁸Vgl. Wäldchen/Mäder 2017, S.510

3 Auswertung

3.1 Metadaten

In diesem Kapitel wird die erste Forschungsfrage thematisiert: *Was für eine Verteilung der Metadaten ergibt sich über alle untersuchten Publikationen hinweg?* Wie bereits in Kapitel 2.2 beschrieben, ist eine Auswertung dieser Metadaten notwendig, um die Aussagekraft dieser SLR zu bewerten. Dies soll eine zu einseitige Betrachtung des aktuellen Standes der Forschung verhindern. Hierfür werden in diesem Kapitel folgende Merkmale ausgewertet:

1. Publikationstyp
2. Durchführungsort der Forschung
3. Fachgebiete der Autoren
4. Wissenschaftliche Bibliothek
5. Veröffentlichungsjahr

Als Publikationstyp sind gemäß Forschungsmethodik, wie in Kapitel 2 beschrieben, nur die Typen *Journal* und *Konferenz* zulässig. Als Durchführungsort der Forschung wird der Ort der Anstellung der beteiligten Forscher erfasst. Hierbei werden im Fall von internationalen Forschungsoperationen alle beteiligten Nationen erfasst, weshalb in der Auswertung mehr Länder als eigentliche Publikationen erscheinen. Bezüglich der Auswertung der Fachgebiete der Autoren sind für die Auswertung vor allem das Verhältnis von Informatik- und Biologie-Hintergründen und derer Kombination relevant. Entsprechend der Forschungsmethodik sind die wissenschaftlichen Bibliotheken der Publikationen auf acht vordefiniert. Das Veröffentlichungsjahr gibt Aufschluss über die Aktualität der Forschung.

In dieser SLR wurden insgesamt 91 Primärquellen ausgewertet. Von diesen 91 Publikationen sind 48 Journalbeiträge und 43 Konferenzbeiträge. Die beiden Kategorien sind mit 53% und 47% ausgeglichen in der Datenbasis repräsentiert.

Eine Analyse der Durchführungsorte der Forschung gibt Aufschluss über die geografische Bedeutung der Thematik. Die ausgewählte Methodik (vorwärts und rückwärts gerichtetes Snowballing) zur Selektion der in dieser SLR betrachteten Publikationen ist anfällig für eine einseitige Betrachtung der Forschung, wenn die Autoren der Primärliteratur sich oft selbst oder nahestehende Kollegen zitieren und andere Forschungsansichten nicht berücksichtigen. Ein Indikator für diese Nähe kann die geografische Herkunft des Gedankenguts sein. Unsere Auswertung der Durchführungsorte der Forschung zeigt eine ausgewogene geografische Verteilung aus einer Vielzahl von Ländern. Lediglich China sticht mit 26 Publikationen aus der Masse deutlich heraus. Gebiete, die durch keine Publikation in unserem Datenset vertreten sind, sind in der Karte in Abbildung 1 hellgrau eingefärbt. Diese Länder befinden sich aber vorwiegend in unterentwickelten Teilen der

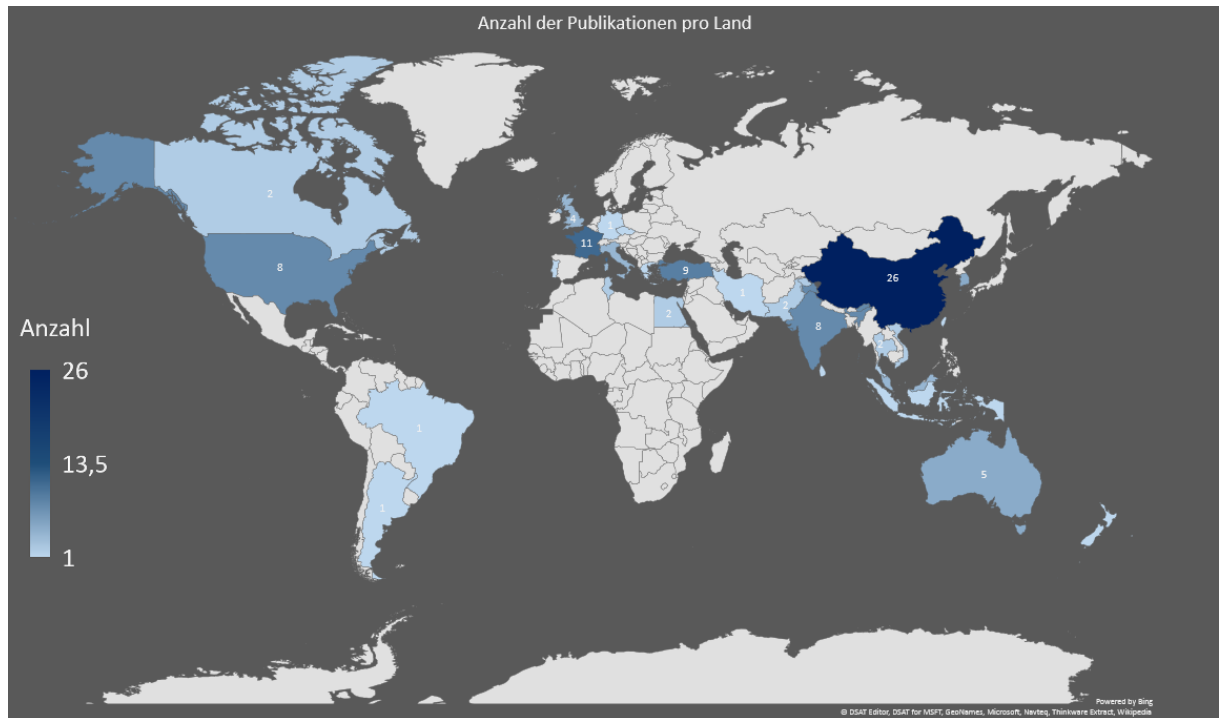


Abbildung 1: Auswertung der Durchführungsorte der Forschung nach Land.

Erde. Es scheint deshalb, dass dies keine Schwäche der gewählten Forschungsmethodik und damit der Aussagekraft dieser SLR darstellt. Sondern dass diese Gebiete bisher schlicht noch keine bedeutenden Forschungsergebnisse im Bereich der automatisierten, visuellen Artenklassifizierung beigetragen haben.

Die Auswertung der Durchführungsorte der Forschung nach Kontinent zeigt, dass Asien mit 63 Publikationen mengenmäßig den größten Beitrag zur Forschung leistet. Die vollständige Auswertung ist in Abbildung 2 dargelegt. Auffällig ist außerdem die verhältnismäßig geringe Anzahl an Publikationen durch Forscher in Nord-Amerika, welche nur 10 Publikationen veröffentlichten, welche durch die gewählte Identifikationsmethodik (siehe Sektion 2.3) in das Datenset gelangt sind. Denn eigentlich ist Nordamerika, und insbesondere die USA, sehr aktiv in der Forschung an Artificial Intelligence.³⁹

Für die Auswertung der Fachgebiete der Autoren der Publikationen sind die möglichen Kategorien Biologie, Informatik und Sonstige und alle Kombinationen dieser gewählt worden. Diese Auswahl hilft zu analysieren, worauf der Fokus des Eigenanteils der Forschung liegt. Dabei ist auffällig, dass mit 51 Publikationen bei den meisten Forschungen ein klarer Fokus auf der Informatik liegt. Es stellt sich heraus, dass diese Forscher meist rein statistische und sehr abstrakte Methodiken verwenden. Die meisten Publikationen aus dem Bereich der Informatik wurden bei IEEE Xplore Digital Library und Elsevier ScienceDirect gefunden. Ein Grund für das große Interesse aus der Informatik ist vermutlich der große Hype der letzten Jahre um das Thema Artificial Intelligence. Im Gegenzug wird bei Forschungen mit Beteiligung von Experten der Biologie häu-

³⁹Vgl. Niu u. a. 2016, S. 7 ff.

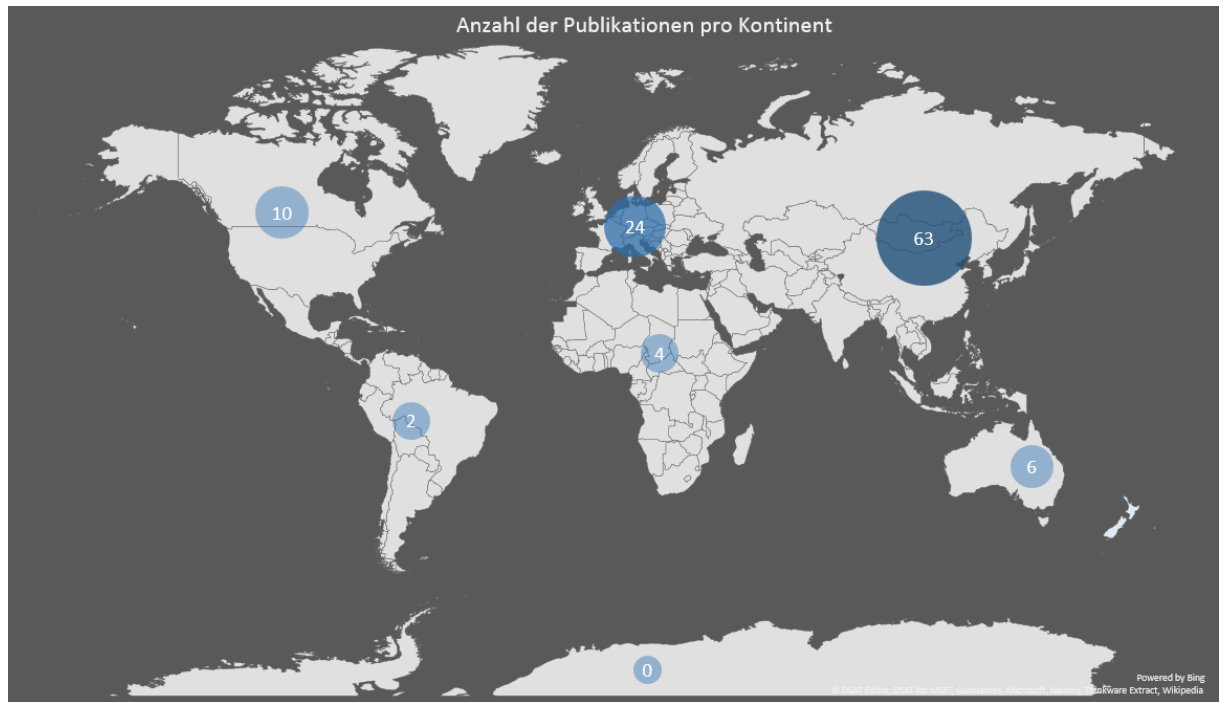


Abbildung 2: Auswertung der Durchführungsorte der Forschung nach Kontinent.

fig ein deskriptiver, näher an traditionellen Klassifizierungsmethodiken angelehnter Ansatz, zum Beispiel durch automatische Extraktion von für den Betrachtungsgegenstand spezifischen Deskriptoren, gewählt. Welche Herangehensweise an das Problem der visuellen Artenklassifizierung bessere Ergebnisse erzielt, kann auf der gegebenen Datenbasis aber nicht abschließend entschieden werden. Die vollständige Auswertung der Fachgebiete ist in Tabelle 1 abgebildet.

Statistisches Mittel	Wert in Jahr
Durchschnitt	2012
Median	2013
1. Quartil	2011
3. Quartil	2014

Tabelle 2: Auswertung der Veröffentlichungsjahre der Publikationen.

Durch eine Auswahl von aktuellen Publikationen soll der aktuelle Stand der Forschung in dieser SLR betrachtet werden. Deshalb werden Quellen, die vor dem Jahr 2002 veröffentlicht wurden, bereits in der Akquisitionsphase gemäß Sektion 2.2 ausgeschlossen. Eine statistische Auswertung der Veröffentlichungsjahre ist in Tabelle 2 zu finden. Das durchschnittliche Veröffentlichungsjahr aller 91 Publikationen liegt bei 2012 mit einem Median im Jahr 2013. Das erste Quartil der Publikationen, sortiert nach Veröffentlichungsjahr, liegt bei 2011, also wurden 25% der Quellen im Jahr 2011 oder früher veröffentlicht. Das dritte Quartil liegt im Jahr 2014, dementsprechend wurden 25% der Publikationen im Jahr 2014 oder später veröffentlicht. Damit ist eine für unsere Zwecke

Fachgebiet der Autoren	Wissenschaftliche Bibliothek	Anzahl an Publikationen
Biologie		4
	Elsevier ScienceDirect	3
	Taylor & Francis	1
Biologie/Informatik		25
	ACM Digital Library	3
	Elsevier ScienceDirect	8
	IEEE Xplore Digital Library	7
	Springer	3
	Taylor & Francis	3
	Wiley Online Library	1
Informatik		51
	ACM Digital Library	2
	Elsevier ScienceDirect	16
	IEEE Xplore Digital Library	28
	ResearchGate	1
	Springer	4
Informatik/Sonstige		4
	CiteSeerX	1
	IEEE Xplore Digital Library	3
Sonstige		7
	Elsevier ScienceDirect	3
	IEEE Xplore Digital Library	2
	Springer	1
	Taylor & Francis	1
Gesamtsumme		91

Tabelle 1: Auswertung der Fachgebiete der Autoren und der veröffentlichenden wissenschaftlichen Bibliotheken.

ausreichende Aktualität der Literatur erreicht um eine aussagekräftige SLR durchzuführen.

3.2 Bildakquise

Im Rahmen der Bildakquise wurden die folgenden Eigenschaften ausgewertet:⁴⁰ Die Anzahl der verwendeten Bilder, aufgeteilt in Größe des Trainings- und Testdatensets, die Quelle der Datensets und die Anzahl der zu unterscheidenden Klassen sowie die Beschaffenheit des Hintergrunds und der zu betrachtenden Objekte. Die Auswertung der Datensets erfolgt unabhängig vom Betrachtungsobjekt, dessen genaue Aufteilung Abbildung 5 zu entnehmen ist, jedoch wird auf das Bildmaterial von Schmetterlingen separat eingegangen, da diese Daten für die abschließende Auswertung benötigt werden.

Zum ersten Punkt, der Gesamtanzahl der verwendeten Bilder, lässt sich sagen, dass im Schnitt 5.561,62 Bilder pro Publikation im Datenset enthalten sind, basierend auf den Daten von 77

⁴⁰ Alle Werte wurden auf die zweite Nachkommastelle gerundet.

Betrachtungsobjekt	Durchschnitt	Min. Wert	Max. Wert	Anzahl Quellen
Alle Objekte	5.600,19	40	270.161	77 von 91
Schmetterlinge	632,38	50	4.530	16 von 17

Tabelle 3: Auswertung der Datenset-Größe.

der 91 ausgewerteten Quellen. Davon reicht die Spannweite von 40 bis zu 270.161 Bildern pro wissenschaftlicher Ausarbeitung wie der Tabelle 3 zu entnehmen ist. Der Durchschnittswert bei den Quellen, die sich mit Schmetterlingen beschäftigt haben, war deutlich niedriger und liegt bei 632,38 Bildern.

Die Aufteilung des Datensets in Trainings- und Testbilder kann bei der Hälfte⁴¹ der Arbeiten entnommen werden und beträgt circa 60% für das Training und 40% für das Testen des Klassifikators.

Betrachtungsobjekt	Externes Datenset	Eigenes Datenset	Keine Angabe
Schmetterlinge	3	13	1
Pflanzen	38	22	0
Andere Insekten	0	7	1
Sonstige	3	2	1
Alle Objekte	44	44	3

Tabelle 4: Auswertung der Bildquellen.

Die Tabelle 4 veranschaulicht die Verteilung der Verwendung von externen Datensets zu eigenen, häufig nur für die Publikation erstellten Datensets. Dabei wird deutlich, dass für die Bildklassifizierung von Schmetterlingen kaum externe Quellen verwendet werden, wohingegen bei Pflanzen fast zwei Drittel aller Quellen sich externe Datensets zunutze machen. Mehrfach werden die Datensets *Flavia*, *Pl@ntLeaves*, *ICL* und *ImageCLEF* oder Teile davon verwendet, welche umfassende Bildquellen für Pflanzen sind, weswegen an dieser Stelle nicht genauer auf diese Bild-Bibliotheken eingegangen wird.

Die Beschaffenheit des Hintergrunds kann in monochrome Verfärbung und natürliche Umgebung eingeteilt werden. Auffallend in Abbildung 3 ist, dass die meisten wissenschaftlichen Arbeiten einen monochromen, also einfarbigen Hintergrund, bevorzugen. Bei der bloßen Betrachtung von Schmetterlingen, wählt jedoch keine Publikation die Erkennung von Schmetterlingen alleinig anhand von Bildern in der natürlicher Umwelt.

Der Zustand der Betrachtungsobjekte wird, wie in Abbildung 4 dargestellt, unterschieden in *präpariert*, *natürlich*, d.h. das Betrachtungsobjekt wird nicht präpariert und befindet sich, bei Tieren, im lebenden Zustand, und *beides*, was bedeutet, dass sowohl präparierte als auch lebende Objekte verwendet werden. Bei Schmetterlingen ist die Verteilung der Zustände relativ ähnlich zu denen der anderen Betrachtungsgegenständen. In der Gesamtheit aller ausgewerteten Quellen überwiegt die Betrachtung von *natürlichen* Objekten (s. linkes Bild der Abbildung 4).

⁴¹Die Aufteilung des Datensets in Trainings- und Testbilder kann 47 der 91 untersuchten Quellen entnommen werden.




Abbildung 3: Auswertung der Hintergrundbeschaffenheit. (*Links* die Verteilung aller Betrachtungsgegenstände, *rechts* nur die der Schmetterlinge.)




Abbildung 4: Auswertung des Zustands der Betrachtungsobjekte. (*Links* die Verteilung aller Betrachtungsgegenstände, *rechts* nur die der Schmetterlinge.)

Betrachtungsobjekt	Durchschnitt	Min. Wert	Max. Wert	Anzahl Quellen
Alle Objekte	45,65	4	330	77 von 91
Schmetterlinge	37,69	5	330	16 von 17

Tabelle 5: Auswertung der Klassen-Größe.

Im Durchschnitt wird in den betrachteten Quellen zwischen etwa 46 unterschiedlichen Klassen unterschieden. Der Tabelle 5 ist dabei zu entnehmen, dass sowohl die Durchschnittswerte als auch die Spannweite der zu klassifizierenden Klassen bei Schmetterlingen im Vergleich zu den anderen Betrachtungsobjekten nicht so massiv abweicht wie es bei den Werten der Größe der Datensets der Fall ist.

Betrachtungsobjekt	Durchschnitt (Klassen pro Datenset-Größe)	Anzahl Quellen
Alle Objekte	104,52	73 von 91
Schmetterlinge	28,55	16 von 17

Tabelle 6: Auswertung des Verhältnisses von Datenset-Größe zur Klassenanzahl.

Werden die Werte *Anzahl der Bilder im Datenset* und *Anzahl der Klassen* in Relation gesetzt (siehe Tabelle 6), werden bei Schmetterlingen im Schnitt 28,55 Bilder pro Klasse verwendet und bei den anderen Betrachtungsobjekten 104,52 Bilder pro Klasse. Diese Ergebnisse verdeutlichen, dass Bilder von Schmetterlingen schwieriger zu beschaffen sind als die von z.B. Pflanzenblättern. Auch ist auffällig, dass zwei Drittel aller Publikationen mit monochromen Hintergrund arbeiten, da viele Konferenzveröffentlichungen⁴²⁴³⁴⁴ von der Prämisse ausgehen, dass dieser sich als störend bei der Erkennung der Objekte erweisen könnte.

3.3 Pre-Processing

In diesem Abschnitt soll die Frage geklärt werden, welche Methoden sich bewährt haben, um das Bildmaterial für die Merkmalsextraktion und anschließender Klassifizierung vorzubereiten. Wie in der vorangegangenen Sektion 3.2 erläutert, werden in zwei Drittel aller Publikationen, Bilder mit einfarbigen Hintergrund für die Bilderkennung verwendet. Von den 14 Datensets, die den natürlichen Lebensraum als Hintergrund wählen, stellen drei Arbeiten⁴⁵⁴⁶⁴⁷ dar, dass sie als ersten Schritt der Bildaufbereitung diesen vor dem Training entfernen.

Als häufigste Pre-Processing-Methode werden die Bilder des Datensets in Graustufen, z.T. in ein binäres Schwarz-Weiß-Bild, umgewandelt. Diese Methode machen sich circa 43% der Arbeiten

⁴²Vgl. Silveira/Monteiro 2009, S. 132

⁴³Vgl. Wang, J. u. a. 2012, S. 104

⁴⁴Vgl. Wen/Guyer, D. 2012, S. 111

⁴⁵Vgl. Apriyanti/Arymurthy/Handoko 2013, S. 54 ff.

⁴⁶Vgl. James Nesaratnam/BalaMurugan 2015, S. 976 ff.

⁴⁷Vgl. Wang, Z. u. a. 2014, S. 2

zunutze, wovon 15 das Schwellenwertverfahren *Otsu* verwenden. Otsu ist ein Verfahren um störende Farbwerte aus dem Bild zu entfernen. Das Resultat ist dabei ein sogenanntes binäres Bild, welches nur weiße und schwarze Pixel enthält.⁴⁸

Oft wird, um die Datensets zu vereinheitlichen, die Skalierung verändert, damit alle Bilder die gleiche Auflösung aufweisen. Acht Publikationen verwenden für das Aufbereiten der Bilder eine teilweise manuelle Extraktion. Weitere Methoden die in den Publikationen genutzt werden, sind Kontrastveränderung, Rotation und Zentrierung des Objekts. Auffallend ist hierbei, dass bei Insekten und Schmetterlingen manchmal nur eine Körperhälfte oder lediglich ein Flügel für die Erkennung verwendet wurden.

Insgesamt können in 78,02% der analysierten Quellen Aussagen über eine Bearbeitung der Bilder zur Vorbereitung für die Mustererkennung gefunden werden. Der darauffolgende Schritt, die Merkmalsextraktion, beginnt im Zuge der Hintergrundentfernung, beziehungsweise der Objekterkennung, meist mit der Extraktion der Konturen. Eine Herangehensweise, die so von zumindest zwölf Arbeiten angewendet wird.

3.4 Merkmalsextraktion

Unter der Zuhilfenahme von charakteristischen Merkmalen lassen sich Schmetterlinge identifizieren und einordnen. Das Bild eines Schmetterlings kann als Sammlung von Pixeln, mit bestimmten Koordinaten und einer bestimmten Farbintensität, beschrieben werden.⁴⁹ Der grundsätzliche Sinn der Merkmalsextraktion ist, die Dimensionalität dieser Matrizen durch die Extraktion charakteristischer Muster zu reduzieren. Diese Muster können beispielsweise Farben, Texturen oder auch Formen sein.⁵⁰ Um hinreichend viele Schmetterlingsarten eindeutig zu identifizieren, müssen morphologische Merkmale extrahiert werden, welche dies ermöglichen. Dieses Kapitel behandelt die Forschungsfrage: *Welche Merkmale wurden insbesondere im Bezug auf die Erkennung von Schmetterlingen extrahiert und welche Techniken wurden dabei verwendet?* Um diese Frage zu beantworten, wird die Merkmalsverteilung der Untersuchung vorgestellt. Diese Verteilung folgt einem stetig steigenden Detaillierungsgrad. Zu Beginn werden die grundsätzlichen Betrachtungsobjekte, danach die extrahierten Organe des Betrachtungsobjektes sowie deren Eigenschaften und zuletzt die exakten morphologischen Eigenschaften der Organe, auch Deskriptoren genannt, untersucht.

3.4.1 Betrachtungsobjekte

Abbildung 5 zeigt die grundsätzliche Verteilung der Betrachtungsgegenstände. Es ist zu erkennen, dass sich fast zwei Drittel der Publikationen (60 von 91) mit der Klassifikation von Pflanzen

⁴⁸Vgl. Sezgin/Sankur 2004, S. 148 ff.

⁴⁹Vgl. Gonzalez/Woods 2008, S.1-2

⁵⁰Vgl. Wäldchen/Mäder 2017, S.9




Abbildung 5: Verteilung der Betrachtungsobjekte.

beschäftigen. Diese Quellen besitzen aufgrund des ähnlich ablaufenden Prozesses bei der allgemeinen Klassifizierung von Arten dennoch eine gewisse Relevanz für die Merkmalsextraktion bei Schmetterlingen. Deutlich weniger (17 von 91), aber für die Analyse deutlich interessantere Quellen beschäftigen sich mit der Erkennung von Schmetterlingen. Darüber hinaus beschäftigen sich acht der 91 betrachteten Artikel mit der Einordnung anderer Insekten. Besonders die beiden letzten Gruppen rücken aufgrund ihrer Relevanz für die Forschungsfrage in den Fokus. Sechs, unter der Kategorie Sonstige aufgeführte Arbeiten befassen sich mit anderen Betrachtungsobjekten wie z.B. anderen Tieren, aber auch Formen und werden im Bezug auf die Merkmalsextraktion in dieser Arbeit nicht weiter betrachtet.

3.4.2 Organe

Die Verteilung der Organe ist nach den unterschiedlichen Betrachtungsobjekten gruppiert in Abbildung 6 dargestellt. Bei der Klassifikation von Pflanzen zeigt sich eine klare Tendenz. Insgesamt nutzen 92% der Quellen ein Blatt der Pflanze, wohingegen gerade 8% der Quellen die Blüte betrachten. Bei der Einordnung von Schmetterlingen und anderen Insekten stellt sich das Ergebnis differenzierter dar. Bei Schmetterlingen wird in 53% der Fälle der gesamte Körper (Corpus und Flügel) zur Klassifizierung genutzt. In 41% der Fälle werden jedoch ausschließlich die Flügel des Schmetterlings genutzt. Außergewöhnlich ist, dass eine Quelle sogar nur die auf den Flügeln der Schmetterlingen zu sehenden Bullaugen-Muster - auch Augenflecken genannt⁵¹ - zur Klassifizierung verwendet. Für die anderen Insekten ergibt sich eine ähnliche Verteilung: 63% der Quellen nutzen den gesamten Körper. In den restlichen Fällen werden die Flügel betrachtet.

Da hier innerhalb der untersuchten Primärquellen eine geteilte Meinung bezüglich dem Hauptmerkmal vorliegt, wird zur weiteren Auswertung auf die erzielte Genauigkeit im Klassifizie-

⁵¹Vgl. Silveira/Monteiro 2009, S. 130




Abbildung 6: Verteilung der betrachteten Organe.

rungsprozess zurückgegriffen. Die entsprechenden Resultate der Analyse können der Tabelle 7 entnommen werden. Es wird deutlich, dass Primärquellen, in denen der ganze Körper und nicht nur die Flügel betrachtet werden, eine höhere Genauigkeit aufweisen. Für Schmetterlinge beträgt die Genauigkeitsdifferenz bei der Betrachtung der Flügel im Vergleich zum ganzen Körper sogar 13%. Dies sind 9% mehr als bei anderen Insekten. Da aus den extrahierten Daten keine anderen offensichtlichen Korrelationen als Erklärung für eine Differenz in einem solchen Ausmaß identifiziert werden konnten, lässt sich schlussfolgern, dass die Auswahl des Organs, besonders die Entscheidung zwischen Körper und Flügel, eine nicht zu vernachlässigende Auswirkung auf die Genauigkeit der Klassifizierung hat. Zu beachten ist aber, dass die konkrete Differenz der Genauigkeit von vielen weiteren Variablen abhängig ist und deshalb in dieser Form nicht weiter als zum Treffen einer generellen Aussage belastbar ist.

Betrachtungsobjekt	Körper	Flügel	Differenz
Schmetterlinge	87%	74%	13%
Andere Insekten	90%	86%	4%

Tabelle 7: Durchschnittliche Klassifikationsgenauigkeit im Bezug auf die betrachteten Organe.

3.4.3 Eigenschaften

Um ein einheitliches Verständnis über die hier verwendeten Eigenschaften zu schaffen, werden diese im Folgenden kurz vorgestellt. In Abbildung 7 ist bei der Klassifizierung von Pflanzen eine deutliche Tendenz bei der Extraktion dieser Muster zu erkennen. Insgesamt 77% der Quellen




Abbildung 7: Verteilung der betrachteten Eigenschaften.

beschäftigen sich mit der Untersuchung der Form des extrahierten Organs. Mit der Farbe und Textur hingegen beschäftigen sich mit 15% und 8% verhältnismäßig wenige Quellen. Dieses Erkenntnis lässt sich auch auf die Einordnung anderen Insekten übertragen. Auch hier ist deutlich zu erkennen, dass die Form von der Mehrheit der Quellen untersucht wird (60%) und die Textur nur selten betrachtet wird (10%). Allerdings betrachten mit 30% der Quellen ebenfalls relativ viele Quellen die Farbe des untersuchten Organs. Werden ausschließlich die Quellen betrachtet, die sich mit der Klassifizierung von Schmetterlingen beschäftigen, so stellt sich das Bild differenzierter dar. 44% der Quellen beschäftigen sich mit der Form des extrahierten Organs. Im Bezug auf Schmetterlinge lässt sich der Bereich der häufig betrachteten Eigenschaften allerdings noch um die Farbe (30%) und die Textur (26%) erweitern. Interessant ist dabei vor allem, die im Gegensatz zu den anderen Betrachtungsgegenständen häufige Betrachtung der Textur.

Um ein fundiertes Bild zu bekommen, müssen zwangsläufig die Kombinationsmöglichkeiten der Eigenschaften beachtet werden. Tabelle 8 zeigt die Verteilung der Quellen, die sich, gruppiert nach den Betrachtungsobjekten, mit der Analyse von nur einer Eigenschaft oder zwei Eigenschaften beschäftigen. Quellen, die sich mit der Betrachtung von allen drei Eigenschaften beschäftigen, machen mit einer Anzahl von sechs aus 85 nur einen Anteil von 7% am gesamten Datenmaterial aus. Aufgrund fehlender Repräsentativität werden diese Quellen im weiteren Verlauf vernachlässigt. Insgesamt zeigt sich in den erhobenen Daten eine deutliche Tendenz zur Untersuchung von nur einer Eigenschaft (73% zu 27%). Am deutlichsten zeigt sich diese Tendenz bei Pflanzen (77% zu 23%). Im Bezug auf Schmetterlinge (71% zu 29%) und anderen Insekten (62% zu 38%) kann eine zunehmend kleinere Differenz festgestellt werden.

Auf Basis der erhobenen Daten lässt sich, wie in Abbildung 9 zu sehen ist, schließen, dass die Verwendung von mehr als einer Eigenschaft durchaus einen Einfluss auf die Genauigkeit

Betrachtungsobjekt	1 Eigenschaft	2 Eigenschaften
Pflanzen	77%	23%
Schmetterlinge	62%	38%
Andere Insekten	71%	29%
Gesamt	73%	27%

Tabelle 8: Kombination verschiedener Eigenschaften.

des Klassifikators hat und grundsätzlich ein genaueres Ergebnis ermöglicht. Verdeutlicht werden kann dies daran, dass die Verwendung mehrerer Eigenschaften bei der Betrachtung von Pflanzen durchschnittlich 6% und bei Schmetterlingen 7% genauer ist. Bei anderen Insekten kann keine solche Präzisionsdifferenz abgeleitet werden. Allerdings kann dieser Sachverhalt auf die geringe Anzahl an untersuchten Quellen (6 aus 79) zurück geführt werden.

Betrachtungsobjekt	1 Eigenschaft	2 Eigenschaften	Differenz
Pflanzen	81%	87%	6%
Schmetterlinge	83%	90%	7%
Andere Insekten	88%	88%	-

Tabelle 9: Durchschnittliche Genauigkeit des Klassifikators nach Anzahl der betrachteten Eigenschaften.

Konkretisiert ergibt sich bezogen auf die Kombinationsmöglichkeiten mit zwei Eigenschaften folgende, allgemeingültige Verteilung: In 65% aller Fälle werden Farbe und Form miteinander kombiniert, in 25% Form und Textur und in 10% der Fälle werden Farbe und Textur betrachtet.

Um zu einer Aussage bezüglich der Auswirkung der Kombination verschiedener Eigenschaften zu gelangen, wird erneut die damit in Zusammenhang stehende Genauigkeit bei der Klassifizierung der Betrachtungsobjekte untersucht. Tabelle 10 zeigt die Auswertung dieser Analyse. Auf Basis des zugänglichen Datenmaterials lassen sich keine größeren Diskrepanzen in der Genauigkeit der Klassifikatoren der Kombinationsmöglichkeiten identifizieren. Die Kombinationsmöglichkeiten sind daher vor dem Hintergrund des Aufwands zu bewerten. Zu beachten ist, dass einige Eigenschaftskombinationen im untersuchten Datenset nicht auftreten und daher mit *Keine Quelle* markiert sind.

Beobachtungsgegenstand	Farbe/Form	Farbe/Textur	Form/Textur
Pflanzen	87%	Keine Quellen	91%
Schmetterlinge	90%	89%	Keine Quellen
Andere Insekten	88%	Keine Quellen	Keine Quellen

Tabelle 10: Durchschnittliche Genauigkeit des Klassifikators nach kombinierten Eigenschaften.

3.4.4 Deskriptoren

Für die Betrachtung der Deskriptoren werden aufgrund der Relevanz für die Konstruktion des Klassifizierungssystems nur solche Quellen betrachtet, die sich mit der Einordnung von Schmet-

terlingen und anderen Insekten auseinandersetzen. Auf Basis der ursprünglich betrachteten 25 Quellen, die sich mit der Klassifizierung von Schmetterlingen und anderen Insekten beschäftigten, werden gemäß den Schlussfolgerungen der vorherigen Kapitel nun nur noch 21 Quellen verwendet. Diese teilen sich auf in sechs Quellen, die sich mit der Analyse anderer Insekten beschäftigen und 15 Quellen, die sich mit der Analyse von Schmetterlingsarten beschäftigen. Abbildung 8 zeigt die Verteilung der Deskriptoren der untersuchten Quellen. Zu beachten ist, dass in einer Quelle mehrere Deskriptoren mit einander kombiniert werden können und somit ein größere Gesamtheit auftreten kann. In grün dargestellt sind Deskriptoren, die sich auf die Eigenschaft der Form beziehen. In blau sind die Deskriptoren zu sehen, die sich auf die Eigenschaft der Textur beziehen und in grau dargestellt sind die Deskriptoren, die sich auf unterschiedliche Eigenschaften des Organs beziehen.




Abbildung 8: Verteilung der Deskriptoren.

Bei der ersten Betrachtung der Daten kann festgestellt werden, dass sich das Feld der Deskriptoren als äußerst diversifiziert darstellt. Häufig handelt es sich hierbei um das in den wissenschaftlichen Artikeln bezüglich innovativen Neuentwicklungen untersuchte Feld. Deutlich zeigt sich das an dem großen Anteil an Deskriptoren, die entweder in dem zugrunde liegenden Datenset nur vereinzelt vorkommen (*Vereinzelte*) oder von den Autoren selbst entwickelt wurden (*Eigene*). Insgesamt machen diese beiden Kategorien zusammen einen Anteil von 45% am Datenset aus.

Da sich aufgrund der geringen Größe des Datensets und der Variation an Deskriptoren keine Aussage über einen Zusammenhang zwischen Deskriptoreinsatz und Ergebnisgenauigkeit treffen lässt, basiert die Relevanz eines Deskriptors alleinig auf dessen Verbreitung im vorliegenden Datenset. Im Folgenden sind die Ergebnisse dieser Analyse zu sehen. Wie Grafik 8 zu entnehmen ist, werden im Bezug auf die Eigenschaft Farbe hauptsächlich *Color Histogram* ge-

nutzt.⁵²⁵³ Für die Eigenschaft Form kommen vor allem Branch Length Similarity (BLS)⁵⁴⁵⁵⁵⁶⁵⁷, Simple and Morphological Shape Descriptors (SMSD)⁵⁸⁵⁹⁶⁰ und Scale Invariant Feature Transform (SIFT)⁶¹⁶²⁶³ zum Einsatz. Wird die Textur betrachtet, sind es vor allem Grey Level Co-occurrence Matrix (GLCM)⁶⁴⁶⁵⁶⁶ und Local Binary Pattern (LBP).⁶⁷⁶⁸ Nachfolgend werden diese Deskriptoren daher genauer vorgestellt:

Branch Length Similarity Dieser Deskriptor gehört zur Kategorie der Formenerkennung und wird bereits vielfältig eingesetzt. Ein Beispiel zur Illustration seines Einsatzes: BLS wird bereits bei der Erkennung von Gefühlen in menschlichen Gesichtern verwendet. BLS ist eine Methode zum Erkennen von Umrissen von Gegenständen auf Bildern. Dabei wird sozusagen ein Verzweigungsnetzwerk erstellt, bestehend aus einem einzelnen zentralen Knoten und abgehenden Zweigen nach außen in verschiedene Richtungen. Diese erstellte Struktur - das sogenannte Grenzform-Muster - ist verhältnismäßig einmalig pro Betrachtungsgegenstand und kann daher gut zur Klassifizierung verwendet werden.⁶⁹⁷⁰

Simple and Morphological Shape Descriptors Dies ist eine Kombination von mehreren Deskriptoren, die in gemeinsamer Verwendung eine qualitative Unterscheidung von Arten ermöglichen. Dabei handelt es sich beispielsweise um eine Korrelation zwischen berechneter Fläche, Umfang, Rundheit und dem berechneten Seitenverhältnis des zu betrachtenden Gegenstandes. Es können jedoch auch weitaus komplexere Formanalysen verwendet werden. Zur Analyse dieser Deskriptoren wird eine einfache Skalierungs- und Normierungsprozedur verwendet, um die Deskriptoren für unterschiedliche Aufnahmesituationen invariant zu machen.⁷¹⁷²⁷³

Scale Invariant Feature Transform In seiner Formulierung umfasst SIFT ein Verfahren zum Detektieren von Interessenpunkten in einem Graustufenbild, bei dem Statistiken von lokalen

⁵²Vgl. Zhu, L./Zhang, Z./Zhang, D. 2015

⁵³Vgl. Wang, J. u. a. 2012

⁵⁴Vgl. Kang/Jeon/Lee 2012

⁵⁵Vgl. Kang/Cho/Lee 2014

⁵⁶Vgl. Kang/Song/Lee 2012

⁵⁷Vgl. Lee/Kang 2016

⁵⁸Vgl. Wang, J. u. a. 2012

⁵⁹Vgl. Silveira/Monteiro 2009

⁶⁰Vgl. Thipayang/Benjamas/Hanboonsong 2013

⁶¹Vgl. Feng/Bhanu 2013

⁶²Vgl. Larios u. a. 2008

⁶³Vgl. Wen/Guyer, D. E./Li 2009

⁶⁴Vgl. Kayci/Kaya 2014

⁶⁵Vgl. Kaya/Kayci 2014

⁶⁶Vgl. Feng/Bhanu 2013

⁶⁷Vgl. Kaya/Kayci/Uyar 2015

⁶⁸Vgl. Kaya/Kayci/Tekin u. a. 2013

⁶⁹Vgl. Kang/Cho/Lee 2014, S.143

⁷⁰Vgl. Kang/Song/Lee 2012, S.432

⁷¹Vgl. Pauwels/de Zeeuw/Ranguelova 2009

⁷²Vgl. Du/Wang, X.-F./Zhang, G.-J. 2007

⁷³Vgl. Wäldchen/Mäder 2017, S. 4

Gradientenrichtungen von Bildintensitäten akkumuliert wurden, um eine zusammenfassende Beschreibung der lokalen Bildstrukturen zu erhalten. Mithilfe dessen können die entsprechenden Interessenpunkte zwischen verschiedenen Bildern verglichen werden, was eine Identifizierung und Klassifizierung ermöglicht.⁷⁴

Gray Level Co-Occurrence Matrix Aus dem Bereich der Texturenanalyse ist GLCM einer der am häufigsten verwendeten Deskriptoren. GLCM erzeugt statistische und korrelationsbasierte Informationen, visuelle Charakteristiken und leitet informationstechnische Maßnahmen zur Interpretation ab. Konkret bedeutet das, dass die Beziehungen zwischen den betrachteten Referenzpixeln und benachbarten Pixeln kalkuliert werden, um daraus die strukturellen Merkmale des Bildes zu bestimmen. Damit eignet sich GLCM sehr gut um raue und glatte Oberflächen zu klassifizieren.⁷⁵

Local Binary Pattern Dieser Deskriptor gehört ebenfalls mit zu den meistverwendeten Deskriptoren der Texturenanalyse. Der LBP-Operator ist ein leistungsfähiges Mittel zur Texturenanalyse und beschreibt ein Graustufen-invariantes Texturmaß, das eine allgemeine Definition der Textur in Kombination mit der lokalen Nachbarschaft ableitet. LBP kann als vereinheitlichendes Texturmodell angesehen werden, welches Mikroinformationen und deren statische Verteilungsregeln zusammenfasst.⁷⁶

Color Histogram Das Farbhistogramm ist eines der am häufigsten verwendeten Farbdeskriptoren, welches die Farbverteilung in einem Bild kennzeichnet. Auch hier gibt es unterschiedliche Herangehensweisen der Autoren, wie die exakte Farbverteilung berechnet wird, jedoch verfolgen alle Deskriptoren ein gleiches Ziel. Ein Farbhistogramm reflektiert die Anzahl der Pixel einer bestimmten Farbe, die in einem Bild gemeinsam sind. Abschließend wird mithilfe eines Schnittmengenhistogramms der Untersuchungsgegenstand identifiziert und klassifiziert.⁷⁷

3.5 Klassifikation

Im Sinne der in Unterkapitel 2.2 genannten Forschungsfrage: *Welche Klassifikatoren kamen zum Einsatz und welche liefern die beste Genauigkeiten bei der Artenerkennung?* fokussiert sich der folgende Absatz mit dem Thema der Klassifikatoren, welche in den recherchierten Quellen genutzt wurden. Die wichtigsten und am häufigsten verwendeten Klassifikatoren werden dabei zuerst definiert und anschließend statistisch ausgewertet im Bezug auf ihre Verwendung in der untersuchten Literatur.

⁷⁴Vgl. Du/Wang, X.-F./Zhang, G.-J. 2007, S. 303

⁷⁵Vgl. Kaya/Kayci/Uyar 2015, S.133

⁷⁶Vgl. Kaya/Kayci/Tekin u. a. 2013, S.268

⁷⁷Vgl. Manjunath u. a. 2001, S. 2

Ein Klassifikator bezeichnet einen Algorithmus, der Objekte, welche durch eine Anzahl an Merkmalen charakterisiert ist, einer oder mehreren Klassen zuordnet.⁷⁸ Klassen sind diesem Anwendungsfall mit Mengen gleichzusetzen und fassen Elemente in eine ungeordnete Einheit zusammen. Dabei wird umgangssprachlich nicht zwischen *Klassifizieren* und *Klassieren* unterschieden, wobei ersteres das Einordnen in eine neue Klasse und letzteres das Einordnen in eine bereits existierende Klasse bezeichnet.⁷⁹ Im Folgenden wird deswegen auch weiterhin *Klassifizieren* verwendet, obwohl in allen untersuchten Publikationen stets in, durch eine Liste vordefinierte, bereits existierende Klassen eingeordnet wird. In dem vorliegenden Anwendungsfall, der Klassifikation von Schmetterlingsbildern, wird ein Bild, oder meist die aus dem Bild zuerst extrahierten Merkmale, durch einen Klassifikator einer Klasse zugeordnet.

3.5.1 Definition verschiedener Klassifikatoren

Im Folgenden werden bestimmte Familien von gängigen Klassifikatoren erläutert. Die meisten dieser Klassifikatoren bieten die Möglichkeit eine Vielzahl von Anpassungen, z.B. durch Hyperparameter, vorzunehmen.⁸⁰ Im Folgenden sind die grundsätzlichen Funktionsweisen und Annahmen der Methoden erläutert. Diese leichte Abstraktion ist notwendig um anschließend eine Aggregation zur statistischen Auswertung vorzunehmen.

Neuronale Netze

Neuronale Netze sind Computersysteme, welche lose an die Funktionsweise eines menschlichen Gehirns angelehnt sind. Sie stellen einen Versuch dar die in der Gehirnforschung gewonnenen Erkenntnisse über das Zusammenspiel aus Nervenzellen (Neuronen) und deren Verbindungen (Synapsen) zu modellieren.⁸¹ Diese neuronalen Netze werden daher auch als Artificial Neural Network (ANN) bezeichnet, da sie lediglich eine Abstraktion der echten biologischen Vorgänge darstellen.

Die Nodes im Netz sind mittels mathematischer Funktionen aneinander gekettet, welche ähnlich wie Synapsen durch neues Input umgestaltet werden können.⁸² Dieses Input kann durch interne oder externe Informationen, die durch das Netz während der Lernphase fließen, bereitgestellt werden.⁸³ Ein Neuronales Netz besteht aus mehreren Layern, welche jeweils eine fixe Anzahl an Nodes beinhalten und die logische Abfolge des Netzes definieren. Ein beispielhaftes, einfach gebautes Netz kann wie in Abbildung 9 beschrieben werden. Solch ein Netz besteht aus einem Input Layer, welches die Informationen anhand einer nicht-linearen Transformation Φ umwandelt. Diese Transformation projiziert die nun linear-separaten Daten auf die zweite Ebene, den

⁷⁸Vgl. Bothe 1993, S. 181

⁷⁹Vgl. Jungclaussen 2013, S. 56 f.

⁸⁰Vgl. Alpaydin 2014, S. 420

⁸¹Vgl. Trinkwalder 2016, S. 130

⁸²Vgl. Sammut/Webb 2011, S. 716

⁸³Vgl. Sammut/Webb 2011, S. 44

Hidden Layer. Der Begriff *Hidden* bezieht sich auf die Eigenschaft der Nodes, dass sie weder Input noch Output Nodes sind. Die Neuronen im Output Layer nehmen anschließend die Informationen aus dem Hidden Layer auf, führen eine letzte Transformation durch und repräsentieren ein Ergebnis.⁸⁴




Abbildung 9: Einfaches neuronales Netz (Multi-Layer-Perceptron).⁸⁵

Eine wichtige Ausprägung neuronaler Netze sind die Convolutional Neural Networks (CNNs), welche im Folgenden näher betrachtet werden.

Convolutional Neural Network (CNN) Als Variante eines Multilayer-Perceptron (MLP) sind CNNs speziell für die Bildverarbeitung geeignet. Sie werden ebenso wie viele andere neuronale Netze mittels Back-Propagation Algorithmen trainiert, aber ihr Alleinstellungsmerkmal ist die Architektur des Netzes. Ein CNN ist auf die direkte Erkennung von visuellen Mustern ausgelegt, welches bloß minimale Vorbearbeitungen der Daten benötigt. So können Muster mit großer Variabilität (wie zum Beispiel handschriftliche Texte) erkannt werden. Das Netz wird so konstruiert, dass das Bild ausschnittsweise in einem *Local Receptive Field* analysiert wird. Das *Local Receptive Field* wird anschließend verschoben und dessen neuer Inhalt wird mit weiteren Neuronen verknüpft, wobei die Gewichtung der Kanten gleich bleibt. Nach Betrachtung des gesamten Bildes wird durch die unterschiedlich starke Aktivierung der Neuronen ein neues, gefiltertes Bild erzeugt, welches für die nächste Ebene als Eingabe dient. Nach mehreren dieser Convolution-Subsampling-Schritte sind mehrere Basisstrukturen und -Texturen erkannt und extrahiert worden, welche am Ende den vollständig verknüpften Neuronenschichten als Entscheidungskriterien für die letztendliche Klassifikation dienen.⁸⁶

Die Anzahl der *Feature Maps* gibt die Anzahl der verschiedenen Faltungen (Convolutions), auch als Filteroperationen bezeichnet, an, die auf den vorigen Layer angewendet werden. Die Gewichtungen bleiben für jede Feature Map in einem Durchgang identisch. Ziel des Subsampling Layers ist das Verwerfen von überflüssigen Informationen, sodass nur wichtige Merkmale und Muster anschließend betrachtet werden.

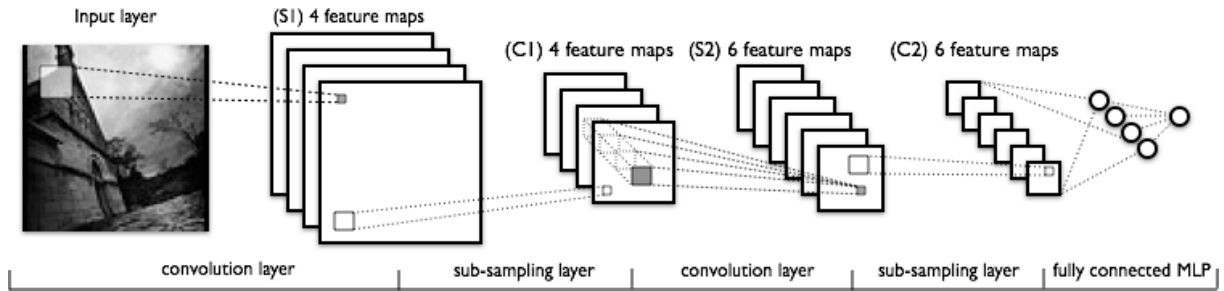
Der Vorteil gegenüber klassischen MLPs, bei denen alle Nodes mit den gesamten Nodes des darauffolgenden Layers verbunden sind, ist dabei vor allem die Geschwindigkeit. Da in einem

⁸⁴Vgl. LISA lab. o. J.b

⁸⁵Abbildung entnommen aus: LISA lab. o. J.b

⁸⁶Vgl. Trinkwalder 2016, S. 130

⁸⁷Abbildung entnommen aus: LISA lab. o. J.a

Abbildung 10: Schematische Abbildung eines CNN.⁸⁷

Convolution Layer immer ganze Bildausschnitte verarbeitet werden und beim Verschieben des *Local Receptive Field* die Gewichtungen der Kanten gleich bleiben, werden viele Berechnungen, vor allem bei dem aufwändigen Updaten der Gewichtungen, erspart. Diese Ersparnis erlaubt eine höhere Anzahl an Layern ohne an Performanz zu verlieren. Außerdem ermöglichen diese gleichbleibenden Gewichtungen CNN eine Robustheit gegenüber Verschiebung und Rotation.⁸⁸

Extreme Learning Machines Eine weitere Variante von neuronalen Netzen sind die Extreme Learning Machines (ELMs). Sie sind normale MLPs mit einem oder mehreren Hidden Layern. Im Unterschied zu normalen MLPs werden bei ELMs die Nodes der Hidden Layer zu Beginn mit zufälligen Parametern belegt, welche im Verlauf der Trainingsphase auch nicht erlernt werden. Lediglich die Gewichtungen der Verbindungen des letzten Hidden Layers zum Output Layer werden in der Trainingsphase über statistische Methoden erlernt. Dies führt zu einer enormen Komplexitätsreduzierung und reduziert im Zuge dessen auch den Berechnungsaufwand während der Trainingsphase bedeutend.⁸⁹

Nearest Neighbour

Eine andere Methode um ein Bild zu klassifizieren ist der Ansatz Nearest Neighbour (NN). Es handelt sich hierbei um einen parameterfreien Klassifikator, da die Analyse direkt auf den Daten aufsetzt und keine explizite Phase zum Lernen/Trainieren benötigt wird. Der Nearest Neighbour Ansatz zählt daher zu den *Lazy Learning* Ansätzen, da das Lernen aus bloßem Abspeichern kategorisierter Daten besteht.

Bei diesem Ansatz wird die Differenz zwischen Datensätzen, zum Beispiel Bildern, gemessen um so die Datensätze zu klassifizieren. Im Kontext der Bildanalyse und Mustererkennung wird das Bild mit anderen, bereits klassifizierten Bildern und deren Deskriptoren verglichen und mittels einer Wahrscheinlichkeitsberechnung klassifiziert. Die Differenz zwischen den Bildern kann mittels mehreren und verschiedensten Deskriptoren erfolgen.⁹⁰

⁸⁸Vgl. Lecun u. a. 1998, S.6

⁸⁹Vgl. Huang/Zhu, Q.-Y./Siew 2006, S.489

⁹⁰Vgl. Ertel 2016, S.206-213

Support Vector Machines

Der Ansatz der Support Vector Machines (SVMs) dient gleichzeitig als Klassifikator sowie als Regressionsmethode. Die Methode unterteilt eine Menge an Objekten in unterschiedliche Klassen. Diese Objekte werden durch einen Vektor im Vektorraum repräsentiert. In diesem Vektorraum wird anschließend nach einer sogenannten Hyperebene gesucht, welche einen möglichst großen Abstand von den unterschiedlichen Objekten im Vektorraum aufweist. Diese Hyperebene wird vollständig durch einige Vektoren im Raum definiert, welche sich Support Vektoren nennen.⁹¹

Linear Discriminant Analysis und Principal Component Analysis

Die Linear Discriminant Analysis (LDA) ist ein statistisches Verfahren um Merkmalsvektoren in ihrer Dimensionalität zu reduzieren, indem eine Anzahl an Linearkombinationen gefunden werden bei denen der Informationsverlust minimal ist. Dies kann entweder als Reduktionsmethode bevor einer Klassifikation eingesetzt werden um den Rechenaufwand durch eine geringere Anzahl an Merkmalen als Input für den Algorithmus zu reduzieren, oder, bei ausreichender Reduzierung der Dimensionalität, zur direkten Klassifizierung.

Dieses Verfahren ist äußerst ähnlich zur Principal Component Analysis (PCA), welches ein Datenset durch eine orthogonale Abbildung in Werte umwandelt, die linear unabhängig voneinander sind. LDA berechnet einen Vektor an Werten, der den Unterschied zwischen den Klassen maximiert, während PCA den Merkmalsvektor mit der größten Varianz kalkuliert.⁹²




Abbildung 11: Unterschied zwischen der Linear Discriminant Analysis und der Principal Component Analysis.⁹³

Die Abbildung 11 zeigt vier Trainingsbeispiele aus zwei verschiedenen Klassen. Diese sind durch Kreise und Kreuze dargestellt. Die zugrundeliegenden Verteilungen sind durch die gepunkteten Ovale symbolisiert. Diese sind dem Algorithmus aber natürlich nicht bekannt. Die vertikale Linie

⁹¹Vgl. Ertel 2016, S.298-300

⁹²Vgl. Martinez/Kak 2001, S.228

⁹³Abbildung entnommen aus: Martinez/Kak 2001

zeigt den von PCA berechneten Vektor. Die mit (D) gekennzeichneten Linien visualisieren die Entscheidungsschwellen der jeweiligen Verfahren.⁹⁴

Random Forests

Random Forests (RFs) gehören zu den Ensemble Learning Methoden. Diese verwenden mehrere verschiedene Algorithmen zum Lernen. Während der Lernphase werden eine Vielzahl von recht einfach strukturierten Entscheidungsbäumen generiert. Bei der Klassifikation wird dann die Klasse als Ergebnis präsentiert, welche am häufigsten von den einzelnen Entscheidungsbäumen klassifiziert wurde.⁹⁵

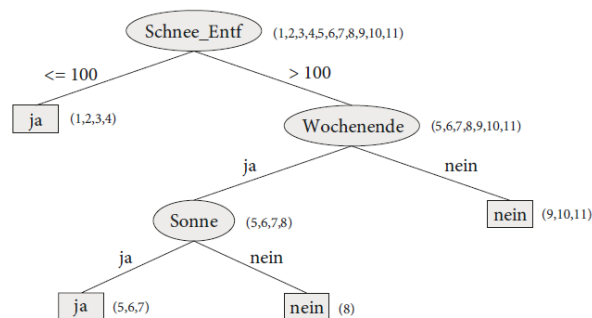


Abbildung 12: Ein einfacher Entscheidungsbaum.⁹⁶

Dieser einfache Entscheidungsbaum zeigt die Grundlagen eines Entscheidungsbaums auf. Er nimmt Merkmale auf, die in den Ovalen genannt werden. Die Merkmalswerte sind ausschlaggebend für die Durchführung weiterer Anfragen. Die Zielvariable ist unten in den Rechtecken angegeben und gibt das Klassifikationsergebnis an. Die Kanten geben die Attributwerte an, anhand derer entschieden wird.⁹⁷ Die Reihenfolge der Merkmalswerte und die Schwellenwerte der Kanten werden während der Trainingsphase erlernt und angepasst.

3.5.2 Verteilung der Klassifikatoren

Analyse der Messverfahren der Genauigkeit

In der untersuchten Literatur werden unterschiedliche Herangehensweisen zur Bewertung der Messgenauigkeit verwendet. Die überwiegende Anzahl an Publikationen verwendet als Genauigkeitskriterium das Verhältnis der korrekten Klassifikationen (*Accuracy*), alsowie viele Bilder den korrekten Klassen zugeordnet wurden. Das Ergebnis liegt dabei zwischen 0% und 100%, wobei letzteres eine vollständig korrekte Klassifizierung aller Bilder präsentiert.


⁹⁴Vgl. Martinez/Kak 2001, S.228

⁹⁵Vgl. Suthaharan 2016, S.273 f.

⁹⁶Abbildung entnommen aus: Ertel 2016

⁹⁷Vgl. Ertel 2016, S.217 f.

⁹⁸Abbildung entnommen aus: Manning/Raghavan/Schütze 2008

Abbildung 13: Precision-Recall Graph.⁹⁸

MAP Das zweite Messkriterium, welches besonders von den 24 Publikationen verwendet wird, die auf den externen Datensets Flavia und Pl@ntleaves basieren, ist der Mean Average Precision (MAP). Dieses Messkriterium stammt ursprünglich aus dem Bereich *Information Retrieval*, welcher sich mit der Frage beschäftigt wie Informationen optimal aus unstrukturierten Datensätzen, die in umfassenden Sammlungen gespeichert sind, optimal zu extrahieren um den Informationsbedarf zu decken.⁹⁹ MAP hat sich in den letzten Jahren als Standard in der *Information Retrieval* Gemeinde etabliert¹⁰⁰ und wird daher in manchen Fällen auch für die Bestimmung der Genauigkeit bei der Mustererkennung verwendet.¹⁰¹¹⁰²¹⁰³¹⁰⁴ Im Gegensatz zu dem auf den ersten Blick hin offensichtlichen Messkriterium der *Accuracy*, erlaubt MAP eine genauere Differenzierung von falschen Positiven und wahren Negativen. Das Kriterium ist sehr sensibel gegenüber dem gesamten Ranking, denn es beinhaltet sowohl Precision- als auch Recallorientierte Aspekte. Der Terminus Precision P beschreibt den Anteil der gewählten Dokumente, die relevant sind. Er wird folgendermaßen berechnet:

$$P = \frac{\#(\text{relevantItemsRetrieved})}{\#(\text{retrievedItems})} = P(\text{relevant}|\text{retrieved})^{105}$$

Der Terminus Recall R beschreibt hingegen den Anteil der relevanten Dokumente, die gewählt wurden und wird so berechnet:

$$P = \frac{\#(\text{relevantItemsRetrieved})}{\#(\text{relevantItems})} = P(\text{retrieved}|\text{relevant})^{106}$$

⁹⁹Vgl. dazu ausführlich Manning/Raghavan/Schütze 2008

¹⁰⁰Vgl. Manning/Raghavan/Schütze 2008, S.159

¹⁰¹Vgl. Mouine/Yahiaoui/Verroust-Blondet 2013a

¹⁰²Vgl. Laga u. a. 2012

¹⁰³Vgl. Mouine/Yahiaoui/Verroust-Blondet 2012

¹⁰⁴Vgl. Mzoughi u. a. 2013

¹⁰⁵Vgl. Manning/Raghavan/Schütze 2008, S.155

¹⁰⁶Vgl. Manning/Raghavan/Schütze 2008, S.155

Diese zwei Werte werden miteinander in der *Precision-Recall-Kurve* in Verbindung gesetzt, sie hat eine distinktive gezackte Form, wie in Abbildung 13 zu sehen ist. Dieser Graph ist zwar sehr informativ, aber um die Ergebnisse verschiedener Publikationen miteinander vergleichen zu können ist es oft gewünscht, die Informationen mit (optimalerweise) einer Kennzahl zu repräsentieren. Diese Kennzahl wird vom MAP verkörpert, da es die Informationen des Graphen und der Relation zwischen Precision und Recall gut zusammenfasst und dennoch gute Diskriminierbarkeit und Stabilität aufweist. MAP ist letztlich der Mittelwert der durchschnittlichen Precision. Es wird die durchschnittliche Precision für jede Abfrage berechnet und anschließend daraus der Mittelwert über alle Anfragen ermittelt. Die Menge der relevanten Dokumente $q_i \in Q$ sei $\{d_1 \dots d_{m_j}\}$ und R_{jk} sei die bewertete Menge der gefundenen Resultate bis einschließlich d_k , so ist

$$MAP(Q) = \frac{1}{|Q|} \sum_{j=1}^{|Q|} \frac{1}{m_j} \sum_{k=1}^{m_j} \text{Precision}(R_{jk})^{107}$$

Wird im schlimmsten Fall kein einziges relevantes Dokument gefunden, so ist das Ergebnis 0. Das Optimum ist 1, obwohl dieses Ergebnis nur sehr schwer zu erreichen ist. Laut Manning/Raghavan/Schütze 2008 schwankt der MAP Wert zwischen 0.1 und 0.7. Für das generelle Interesse ist es wichtig anzumerken, dass viele Publikationen zwar von einem Average Precision Wert sprechen, aber tatsächlich den Interpolated Average Precision Wert berechnen, welcher sich leicht von MAP unterscheidet.¹⁰⁸ Daher wird nochmals die Notwendigkeit unterstrichen, jede Publikation mit höchster Sorgfalt zu betrachten. Bei dieser sorgfältigen Betrachtung erschließt sich zudem, dass mehr als 10% der betrachteten Publikationen nicht die *Accuracy* sondern einen anderen, ähnlichen Wert berechnen.¹⁰⁹¹¹⁰ Auch differenzieren manche der Publikationen zwischen Top-1, Top-3 und/oder Top-5 *Accuracy*. Dies stellt diese Arbeit vor die Herausforderung, eine angemessen differenzierte, aber auch einheitliche Auswertung vorzunehmen, die der späteren Entscheidungsfindung dienen kann. Um dies zu gewährleisten, wird nur der MAP Score differenziert betrachtet und andere mögliche abweichenden Werte werden mit der *Accuracy* gleichgesetzt. Diese Entscheidung beruht auf der Prämisse, dass auch die Publikationen, die eine andere Kennzahl gewählt haben, dies in der Absicht taten, die Genauigkeit ihrer Messungen zu überprüfen und darzustellen. Dieser Kritikpunkt wird in Abschnitt 4.1 ferner diskutiert.

Validierung der Ergebnisse 17 der 91 Publikationen verwenden zur Validierung ihrer Ergebnisse das Kreuzvalidierungsverfahren. Mit diesem Verfahren wird versucht, die Modellkomplexität so zu optimieren, dass a) sie sich nicht zu stark an die Trainingsdaten anpasst (Overfitting) und b) der Klassifikationsfehler auf einer beim Lernen unbekannten Testdatenmenge minimal

¹⁰⁷Vgl. Manning/Raghavan/Schütze 2008, S.155

¹⁰⁸Vgl. dazu ausführlich Everingham u. a. 2010

¹⁰⁹Vgl. Mouine/Yahiaoui/Verroust-Blondet 2013b

¹¹⁰Vgl. Wang, B. u. a. 2015

wird.¹¹¹¹¹² Dabei wird die Trainingsdatenmenge in eine bestimmte Anzahl k gleich großer Blöcke zerlegt, optimalerweise $k = 10$ oder $k = 5$.¹¹³ Der Algorithmus wird anschließend k mal auf die Daten der $k - 1$ Blöcke trainiert. Sei $k = 10$ bedeutet dies, dass der Algorithmus 10-mal auf 9 Datenblöcke angewendet und an einem Datenblock getestet wird. Der Testblock rotiert bei jedem neuen Durchlauf, sodass immer andere Daten durchlaufen werden.¹¹⁴ Bei den Durchläufen werden die Fehler ermittelt, gemittelt und der Algorithmus wird anschließend so angepasst, dass ein optimaler Trainingsparameter mit dem geringsten mittleren Fehler zum Training des finalen Modells gewählt wird.

Durch diese Kreuzvalidierung entsteht zwar ein sehr viel höherer Rechenaufwand (bei $k = 10$ ist es der elffache), aber die automatische Optimierung der Modellkomplexität löst das Problem des Overfittings.¹¹⁵ Die Resultate der Publikationen, die diese Methode angewendet haben, sind also vertrauenswürdiger als jene, die keiner Kreuzvalidierung unterzogen wurden. Mit diesem Hintergrundwissen lassen sich nun die im folgenden Absatz zu präsentierenden Ergebnisse kritisch hinter blicken.

Präsentation der Ergebnisse

Von den untersuchten Quellen nutzen 26 den Ansatz der Support Vector Machines zur Klassifizierung der Daten, 20 eine Form der neuronalen Netze und 18 Quellen nutzen die Nearest-Neighbour Methode. Des Weiteren wird bei drei Quellen die Random-Forest Methode angewendet und die Methoden Linear Discriminant Analysis und Principal Component Analysis werden je zweimal verwendet. 24 weitere Klassifikatoren, die von den restlichen Quellen verwendet werden, werden im Folgenden vernachlässigt, da ihre rare Verwendung darauf schließen lässt, dass die Methoden nicht ausschlaggebend genug sind um von der wissenschaftlichen Gemeinde als konkrete Klassifikatoren akzeptiert zu werden. Um eine tiefer gehende Analyse vorzunehmen ist es außerdem wichtig, den Fokus der zu betrachtenden Daten korrekt zu definieren und so sind diese selten verwendeten Klassifikatoren zu vernachlässigen.

In der folgenden Abbildung 14 wird die Verteilung graphisch dargestellt. Zu beachten ist hier, dass die Summe der verwendeten Klassifikatoren nicht der Anzahl der betrachteten Publikationen entspricht, da bestimmte Publikationen mehrere Klassifikatoren nutzen um sie anschließend zu vergleichen. Ebenso gilt es zu erwähnen, dass sieben Publikationen keine Angabe zu ihrem verwendeten Klassifikator gemacht haben. Dies weist darauf hin, dass die Ausarbeitungen eventuell lückenhaft sind oder dass tatsächlich keine ordinäre Klassifizierung vorgenommen werden müssen aufgrund einer differenzierten Auswertung. Dies ist für das Ziel dieser Auswertung aber nicht von Relevanz, da dem generellen Konsens in der wissenschaftlichen Gemeinde gefolgt wird und die entsprechend anderen Methoden für das ferne Ziel dieser Arbeit (die Entwicklung einer

¹¹¹Vgl. Ertel 2016, S.232

¹¹²Hastie/Tibshirani/Friedman 2009

¹¹³Vgl. Hastie/Tibshirani/Friedman 2009, S.243

¹¹⁴Vgl. Ertel 2016, S.232

¹¹⁵Vgl. Hastie/Tibshirani/Friedman 2009, S.240

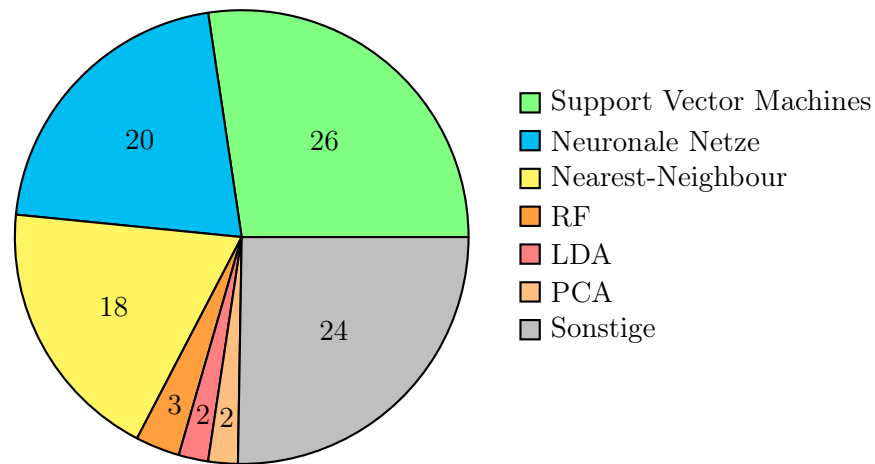


Abbildung 14: Verteilung der Klassifikatoren.

Mustererkennungskomponente) nicht leicht verwendet werden können, da es dazu an Literatur fehlt.

Der am häufigsten verwendete Klassifikator ist der Support Vector Machine. Die Genauigkeit bei den 26 Publikationen mittelt sich bei 89% und zeigt ein Minimum bei 70% und ein Maximum bei 99% vor. Anzumerken ist hier, dass die Ergebnisse der einzelnen Publikationen in sich bereits zwischen fünf Prozent schwanken und daher exakte Werte für Minimum, Maximum sowie den Mittelwert schwer festzustellen sind. 25% dieser Publikationen haben ihre Ergebnisse mittels einer zehnfachen Kreuzvalidierung vor der Gefahr des Overfittings gesichert und diese sind somit besonders aussagekräftig. Je höher der Anteil der kreuzvalidierten Ergebnisse, desto verlässlicher und aussagekräftiger sind die Ergebnisse der Publikationen. Da nicht jede Quelle ihr Vorgehen im Detail schildert, ist davon auszugehen, dass mehr als 25% eine Validierung vorgenommen haben und somit können die Ergebnisse ohne weitere Diskriminierung ausgewertet werden.

Die am zweithäufigsten angewendete Methode ist die der neuronalen Netze. Sie finden in 22% der Publikationen Anwendung. Wie in Unterkapitel 3.5.1 erwähnt, existieren verschiedene Ausprägungen neuronaler Netze. Die meistverwendete Variante ist das ANN, welches siebenmal verwendet wird. CNNs werden fünfmal verwendet und ELMs sowie Probabilistic Neural Network (PNN)s werden je dreimal verwendet, wie in Abbildung 15 zu sehen ist. Eine interessante Beobachtung ist, dass sich die Genauigkeit der Klassifizierung bei den verschiedenen Varianten des neuronalen Netzes sehr ähnlich verhält. Alle zeigen einen Mittelwert von 90% vor, allerdings differenzieren sie sich durch die verschiedenen Minimal- und Maximalwerte. Die geringste Genauigkeit aller hier betrachteten Klassifikatoren weist mit 76% das CNN vor. Es ist überraschend, dass ANNs und nicht CNNs die genauesten Ergebnisse liefern, obwohl letztere auf Bildererkennung ausgelegt sind. Dies liegt möglicherweise aber nicht an der Auswahl des Klassifikators aber an dessen Konfiguration oder den vorhergegangenen Maßnahmen. Eine einzige Publikation weist eine Genauigkeit von 100% vor. Diese nutzt die Methode eines General Regression Neuronalen Netzes, welches in der tiefer gehenden Betrachtung vernachlässigt wurde. Anzumerken ist hier aber, dass das Modell laut Autoren trotz vierfacher Kreuzvalidierung wahrscheinlich overfitted




Abbildung 15: Verteilung der Klassifikator innerhalb der neuronalen Netze.

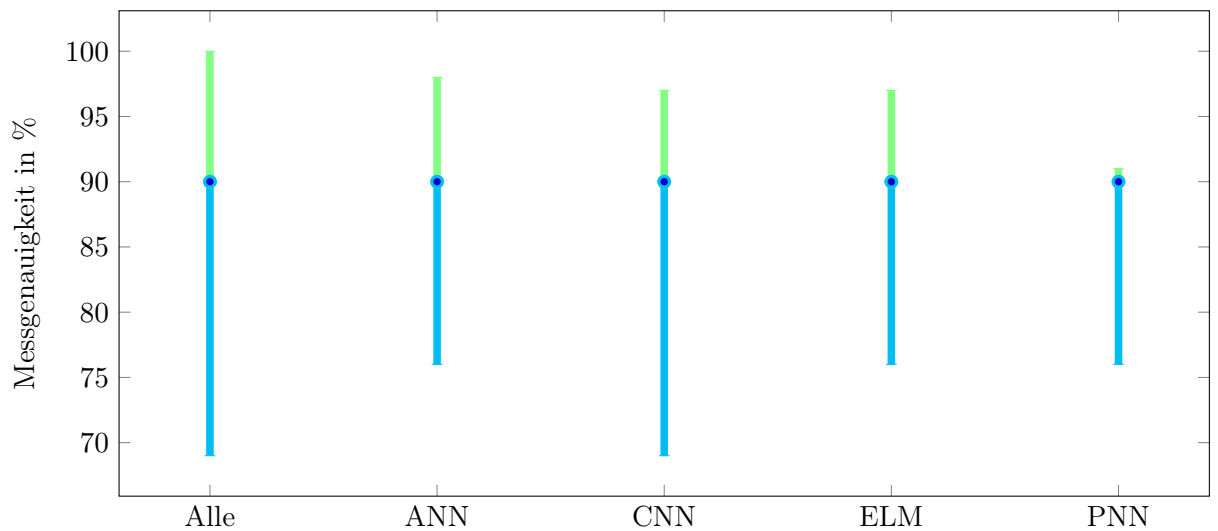


Abbildung 16: Minimum, Mittelwert und Maximum der Messgenauigkeit der Klassifikatoren.

wurde und so dieses Ergebnis bei einem anderen Testset nicht wieder erreicht werden kann. Weniger interessant bei dem Vergleich der neuronalen Netze sind die ELMs und PNNs, da je nur drei Publikationen diese Methoden behandeln und so die Ergebnisse nicht in gleichem Maße zuverlässig sind wie die der übrigen Varianten. Die Ergebnisse der ELMs liegen bei 76%, 97%, 97% und die der PNN bei 76%, 91% und nochmals 91%.

Bei Betrachtung der Publikationen, welche die Nearest Neighbour Methode verwenden, fällt auf, dass der generelle Durchschnitt der Genauigkeit mit 87% unter dem der neuronalen Netze liegt. Zwei Publikationen weisen allerdings eine hohe Genauigkeit von 99% vor. Diese Ergebnisse sind als zuverlässig einzustufen, da für sie eine zehnfache Kreuzvalidierung vorgenommen wird und eine der Quellen ebenso die höchste Anzahl an verwendeten Trainings- und Testdaten aufweist. So ist davon auszugehen, dass das gute Ergebnis nicht durch Overfitting entstanden ist. Zwei der hier betrachteten Publikationen verwenden MAP zur Genauigkeitsbestimmung und werden

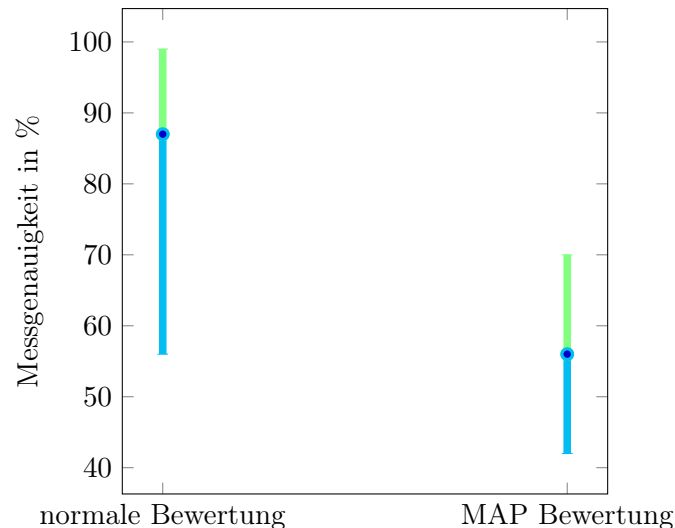


Abbildung 17: Minimum, Mittelwert und Maximum der Messgenauigkeit der Klassifikatoren. Vergleich zwischen Accuracy und MAP.

daher nicht direkt mit den anderen Verfahren verglichen. Ihr MAP-Wert liegt mit 42% und 70% weit unter dem Mittelwert, wie auch in Abbildung 17 zu erkennen ist.

Eine weitere Beobachtung ist, dass bei einer Publikation sogar eine 50-fache Kreuzvalidierung vorgenommen wird und sie dadurch ein zuverlässiges Ergebnis vorweist, das zwischen 80 bis 98% schwankt.

Zur Vollständigkeit der statistischen Auswertung werden im Folgenden die Methoden RF, LDA und PCA betrachtet, obwohl sie kumuliert <10% der ausgewählten Klassifikatoren darstellen. Die Qualität der Ergebnisse dieser Methoden ist außerdem niedrigeren Grades als die der bereits ausgewerteten. So fällt bei Betrachtung der RFs auf, dass in einer Publikation zwar eine zehnfache Kreuzvalidierung vorgenommen worden, aber die Ergebnisse, also die Genauigkeit, nicht genannt werden. Die übrigen zwei Publikationen, nutzen RF als Teilkomponente in Zusammenhang mit SVM und weisen Ergebnisse von 85% sowie 92% auf. Auch die Methoden LDA sowie PCA werden in je einer der Publikationen als Teilkomponente genutzt. Dabei liefert LDA eine Genauigkeit von 81% und 92% und PCA eine Genauigkeit von 89% und 92%. Die gemeinsame Nutzung von Klassifikatoren ist ein wesentliches Problem bei der Auswertung der Genauigkeit, da so die Ergebnisse nicht den konkreten Methoden zugeordnet werden können. Auf dieses Problem muss zwingend hingewiesen werden um eine sorgfältige und kritische Blickweise auf die Ergebnisse zu sicherzustellen.

Des Weiteren unterliegt diese statistische Auswertung weiteren Kritikpunkten. Es genügt nicht, von der Genauigkeit auf die Fähigkeit einzelner Klassifikatoren zu schließen, da das Endergebnis auf vielen Vorarbeiten basiert. So spielen ebenso die Anzahl der Test- und Trainingsbilder, die ausgewählten Organe, die Tiefe des Pre-Processings sowie die gefilterten Merkmale eine wesentliche Rolle bei der Mustererkennung. Eine Betrachtung der Klassifikatoren ausschließlich auf Basis des Endergebnisses ist somit kritisch zu sehen. Aufgrund der verdichteten Informationen,

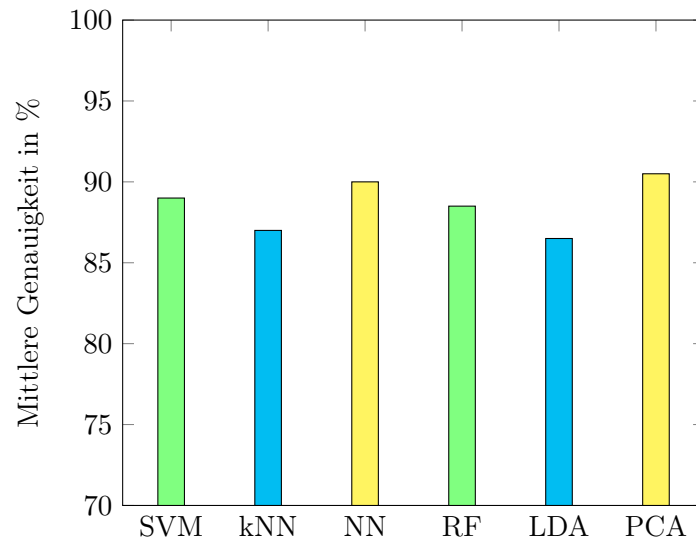


Abbildung 18: Vergleich der Mittelwerte der verschiedenen, analysierten Klassifikatoren.

die in den Publikationen veröffentlicht werden, ist dies aber der beste Einstiegspunkt für eine tiefer gehende Betrachtung. Allein durch die Art und Anzahl der verwendeten Klassifikatoren lässt sich eine Empfehlung aussprechen, welche dieser Methoden am besten für die Mustererkennung bei Schmetterlingen geeignet ist. Diese Empfehlung kann dann anschließend durch die ermittelten Werte, siehe Abbildung 18, unterstützt werden. Zur Differenzierung zwischen dem Nearest NeighbourKlassifikator und der Neuronalen Netze, werden die Abkürzungen *kNN* und *NN* verwendet.

4 Ergebnisse

4.1 Kritische Reflexion

Die Durchführung der SLR ist mit großer Sorgfalt durchgeführt worden. Trotzdem sind durch die Masse an Daten einige Herausforderungen entstanden, deren Überwindung nun kritisch reflektiert werden soll.

Es ist möglich, dass trotz der sorgfältig ausgewählten, bewährten Kriterien für die SLR, Publikationen nicht betrachtet worden sind, die von Relevanz gewesen wären. Da die Kriterien aber mit Bedacht ausgewählt und insgesamt 91 Publikationen ausgewertet worden sind, ist dieses Risiko zu vernachlässigen. Die betrachteten Publikationen bieten einen ausreichenden Hintergrund um darauf für die spätere Entwicklung der Erkennungskomponente aufbauen zu können.

Die angewendete Forschungsmethodik sowie die daraus abgeleiteten Forschungsfragen setzen einen klaren Fokus auf die Auswertung Schmetterlings-bezogener Quellen. Hiermit wird ein Teil der Publikationen von der Analyse ausgegrenzt. Dieser Schritt war allerdings notwendig, da andernfalls der Aufwand für die Analyse der weiteren Daten nicht in Relation mit dem potenziellen Wissensgewinn gestanden hätte.

Die Analyse der Publikationen ist kritisch zu hinterfragen. Viele Angaben der Publikationen sind inkonsistent, die Bewertungskriterien zur Messung der Genauigkeit variieren und werden manchmal auch nicht näher beschrieben, sodass die Analyse von mehreren Prämissen ausgehen muss. Diese Prämissen vermindern die Aussagekraft der Analyse. Ein schwerwiegendes Problem sind vor allem die falsche Zuordnung von Methoden. So werden manche, die in der wissenschaftlichen Literatur klar als Reduktionsmethoden definiert sind, als Klassifikatoren oder Deskriptoren in den Publikationen beschrieben. Auch werden manche Klassifikatoren von Autor zu Autor unterschiedlich benannt, obwohl sie eine gleiche Vorgehensweise aufweisen. Des Weiteren haben manche Quellen keine oder auch mehrere Ergebniswerte präsentiert, welche sich aus Top5-, Top3-, oder Top1-Werten ergeben. In manchen Fällen werden sie als solche präsentiert, aber in anderen Fällen nicht, was die korrekte Analyse der Ergebnisse erschwert.

Ein Problem bezüglich der Auswertung der Publikationen ist die Tatsache, dass die Messgenauigkeit nicht alleine von den, in den unterschiedlichen Kapiteln isoliert betrachteten, Phasen der Klassifizierung abhängig ist. Sie hängt von einer Vielzahl sich gegenseitig beeinflussender Variablen, wie dem Pre-Processing, der Auswahl der Betrachtungsobjekte, Eigenschaften und Deskriptoren, sowie der Auswahl und Nutzung der Klassifikatoren ab. Die Summe dieser Vorarbeiten und das letztliche Klassifizieren, welches trotz gleichen Namens mit verschiedenen Konfigurationen erfolgen kann, liefert das Ergebnis. Die fehlende Beachtung der korrelierenden Faktoren, verleiht den einzelnen Phasen der Klassifizierung daher eventuell eine zu hohe Bedeutung.

4.2 Hauptergebnisse

In Bezug auf die anfangs formulierten Forschungsfragen liefert diese wissenschaftliche Ausarbeitung folgende Antworten:

1. *Was für eine Verteilung der Metadaten ergibt sich über alle untersuchten Publikationen hinweg?* Diese Frage ist von Bedeutung, um die Aussagekraft der ausgewählten Publikationen bemessen zu können. Die betrachteten Eigenschaften ergeben, dass sich ein Großteil der Publikationen auf dem Gebiet der Informatik befindet und eine Problematik im Bereich Computer Vision behandelt. Die Publikationen sind entweder anerkannte Peer Reviewed Journal-Beiträge oder Konferenzbeiträge, welche als zuverlässig und aussagekräftig zu bewerten sind. Viele der Publikationen stammen aus China, doch in ihrer Gesamtheit sind die Veröffentlichungen weltweit verteilt, sodass von keiner Beeinflussung auszugehen ist. Das Veröffentlichungsdatum, welches gemäß den Einschränkungen auf 2002 bis 2018 eingegrenzt ist, liegt im Durchschnitt bei 2012 und impliziert somit eine hohe Aktualität der Veröffentlichungen.
2. *Wie viele Arten wurden auf Basis wie vieler Bilder betrachtet, wie wurden diese Bilder erfasst und in welchem Kontext wurden sie aufgenommen?* Die Analyse ergibt, dass eine Publikation durchschnittlich 5.561,62 Bilder für die Mustererkennung nutzt. Das Minimum liegt bei 40, das Maximum bei 270.161 Bildern. Die Spannweite ist somit sehr groß und weniger aussagekräftig über die Anzahl benötigter Bilder. Werden nur Schmetterlingsbilder betrachtet, liegt der Durchschnittswert mit 632,38 deutlich unter dem vorherigen Wert, da Bilder von Schmetterlingen deutlich weniger verbreitet und schwerer zu beschaffen sind, als die von Pflanzenblättern. Oft werden externe Datensets wie *Flavia*, *Pl@ntLeaves*, *ICL* und *ImageCLEF* genutzt um an Pflanzenbilder zu gelangen. Für Schmetterlinge ist eine solche umfassende Datenbank nicht vorhanden. Die deutliche Mehrheit der verwendeten Bilder nutzt Präparate vor einem monochromen Bildhintergrund, da diese leichter zu verarbeiten sind. Dies wird im Hinblick auf den Anwendungsfall eine Herausforderung darstellen, da die Anwendung für den Alltag gedacht ist und lebende, frei-fliegende Schmetterlinge identifizieren soll. Die genutzten Bilder werden während des Pre-Processings in fast allen Fällen auf eine gleiche Größe skaliert und in Graustufen umgewandelt. Diese bewährte Methode kann auch für die spätere Ausarbeitung der Erkennungskomponente in Betracht gezogen werden.
3. *Welche Merkmale wurden insbesondere im Bezug auf die Erkennung von Schmetterlingen extrahiert und welche Techniken wurden dabei verwendet?* Insgesamt beschäftigen sich 17 der 91 Publikationen ausschließlich mit Schmetterlingen, da dies ein sehr spezifisches Feld der Mustererkennung darstellt. In 53% der Fälle wird der gesamte Schmetterlingskörper für die Klassifizierung betrachtet und in 41% der Fällen nur die Flügel. Da die Betrachtung des gesamten Körpers mit einer höheren Genauigkeit bei der Klassifizierung korreliert, lässt sich darauf schließen, dass dieses Merkmal eher geeignet ist als die alleinige Betrachtung

eines Flügels. Somit sollte in der Komponente ebenfalls der gesamte Körper betrachtet werden. Das Organ des Schmetterlings wird auf Textur, Farbe und Form untersucht, welche im Bezug auf Schmetterlingen in ähnlicher Verteilung auftreten. Im Gegensatz dazu liegt bei Pflanzen mit 77% ein klarer Fokus auf der Betrachtung der Form. Meist werden die Eigenschaften nicht isoliert betrachtet, sondern miteinander kombiniert. In 90% der Fälle wird im Bezug auf Schmetterlinge eine Kombination aus Farbe und Form und in 89% der Fälle eine Kombination aus Farbe und Textur genutzt. Um die Eigenschaften genauer auszuwerten, werden besonders die Deskriptoren BLS und GLCM sowie individuell erstellte Deskriptoren genutzt. Die zuerst genannten können für die spätere Verwendung in der selbst zu erstellenden Komponente nützlich sein.

4. *Welche Klassifikatoren kamen zum Einsatz und welche liefern die beste Genauigkeiten bei der Arterkennung?* In der letzten Phase der Mustererkennung, der Klassifikation eines Bildes, werden hauptsächlich Support Vector Machines oder Neuronale Netze verwendet. Unter Neuronale Netze fallen dabei die generischen Artificial Neural Networks sowie auch Convolutional Neural Networks, Extreme Learning Machines und Probabilistic Neural Networks. Eine andere oft genutzte Methode ist die des Nearest Neighbour. Letztendlich bieten alle Klassifikatoren eine ähnlich hohe Genauigkeit, die bei 90% liegt. Daher sollte für die eigene Komponente ein Klassifikator genutzt werden, der gut dokumentiert, weit verbreitet und eine gute Performanz bietet. Der Fokus sollte nicht auf der hier beschriebenen Genauigkeit liegen, da wie in der kritischen Reflexion bereits beschrieben, diese nicht zu Genüge aussagekräftig ist.

Zusammenfassend lässt sich sagen, dass das Feld der Computer Vision, der maschinellen Bilderkennung, sehr divers ist und es eine Vielzahl an möglichen Kombinationen von Organen, Eigenschaften, Deskriptoren sowie Klassifikatoren existiert, welche alle zu einem zufriedenstellenden Ergebnis von meist >85% führen. Eine einzige geeignete Vorgehensweise anhand dieser Publikationen zu definieren, wird das Projektteam vor eine weitere Herausforderung stellen. Allerdings konnte die SLR dazu beitragen, die grundsätzliche Komplexität auf ein handhabbares Maß zu reduzieren. Darüber hinaus hat sie einen Überblick über potenzielle Vorgehensweisen ermöglicht, der als Grundlage für die Planung des konkreten Vorgehens in der nächsten Projektphase genutzt werden kann.

Anhang

Anhangverzeichnis

A.1	Quellen-Startset	41
A.2	Liste aller ausgewerteten Quellen	43

Anhang 1: Quellen-Startset

Titel	Autor	Jahr	Publiziert in	Bibliothek	Zitationen	Referenzen
A computer vision system for the automatic identification of butterfly species via Gabor-filter-based texture features and extreme learning machine: GF + ELM	Kaya, Y./ Kayci, L./ Tekin, R.	2013	TEM Journal	CiteSeerX	16	22
A Leaf Recognition Algorithm for Plant Classification Using Probabilistic Neural Network	Wu, G.W. u.a.	2007	International Symposium on Signal Processing and Information Technology	IEEE Xplore Digital Library	468	30
A Parametric Active Polygon for Leaf Segmentation and Shape Estimation	Cerutti, G. u.a.	2011	International Symposium on Visual Computing	Springer	49	16
Automatic species identification of live moths	Mayo, M./Watson, A. T.	2006	Knowledge-Based Systems	Elsevier Science Direct	78	14
Image-based orchard insect automated identification and classification method	Wen, C.	2007	Computers and Electronics in Agriculture	Elsevier Science Direct	36	14
Leaf Image Classification with Shape Context and SIFT Descriptors	Wang, Z.	2011	International Conference on Digital Image Computing: Techniques and Applications	IEEE Xplore Digital Library	24	10
Leaf shape based plant species recognition	Du, J.-X./Wang, X.-F./Zhang, G.-J.	2007	Applied Mathematics and Computation	Elsevier Science Direct	299	20

- Fortsetzung der Tabelle auf der nächsten Seite -

Titel	Autor	Jahr	Publiziert in	Bibliothek	Zitationen	Referenzen
Plant Species Identification using Computer Vision Techniques	Mäder, P./Wäldche, J.	2016	International Conference on Natural Computation	Springer	6	159
Recognition of plant leaf image based on fractal dimension features	Du, J.-X./Zhai, C.-M./Wang, Q.-P.	2013	Neurocomputing	Elsevier Science Direct	56	17
The identification of butterfly families using content-based image retrieval	Wang, J. u.a.	2011	Biosystem Engineering	Elsevier Science Direct	35	26

Tabelle 11: Quellen Startset.

Anhang 2: Liste aller ausgewerteten Quellen

- Aakif, A./Khan, M. F. (2015):** Automatic classification of plants based on their leaves, in: Biosystems Engineering, Nr. 139, S. 66–75.
- Ahmed, N./Ghani, U./Asif, S. (2016):** An automatic leaf based plant identification system, in: Science International-Lahore, Nr. 28, S. 427–434.
- Apriyanti, D. H./Arymurthy, A. M./Handoko, L. T. (2013):** Identification of orchid species using content-based flower image retrieval, in: International Conference on Computer, Control, Informatics and Its Applications, Nr. 1, S. 53–57.
- Aptoula, E./Yanikoglu, B. (2013):** Morphological features for leaf based plant recognition, in: Image Processing, Nr. 1, S. 1496–1499.
- Balasaravanan, T./Priya, C. A./Thanamani, A. S. (2012):** An efficient leaf recognition algorithm for plant classification using support vector machine, in: 2012 International Conference on Pattern Recognition, Informatics and Medical Engineering (PRIME), Nr. 1, S. 428–432.
- Barré, P. u. a. (2017):** LeafNet, A computer vision system for automatic plant species identification, in: Ecological Informatics, 40. Jg., Nr. 1, S. 50–56.
- Cannavò, F. u.a. (2012):** Texture Recognition for Frog Identification, in: Proceedings of the 1st ACM international workshop on Multimedia analysis for ecological data, Nr. 1, S. 25–29.
- Cerutti, G. u.a. (2011):** A Parametric Active Polygon for Leaf Segmentation and Shape Estimation, in: International Symposium on Visual Computing, Nr. 7, S. 202–213.
- Cerutti, G. u. a. (2013):** A model-based approach for compound leaves understanding and identification, in: 2013 IEEE International Conference on Image Processing, Nr. 1, S. 1471–1475.
- Cerutti, G. u. a. (2013):** Understanding leaves in natural images – A model-based approach for tree species identification, in: Computer Vision and Image Understanding, 117. Jg., Nr. 10, S. 1482–1501.
- Chaki, J./Parekh, R./Bhattacharya, S. (2015):** Recognition of whole and deformed plant leaves using statistical shape features and neuro-fuzzy classifier, in: Recent Trends in Information Systems, Nr. 2, S. 189–194.
- Chathura Priyankara, H. A./Withanage, D. K. (2015):** Computer assisted plant identification system for Android, in: Moratuwa Engineering Research Conference (MERCon), Nr. 1, S. 148–153.
- Che Hussin, N. A. u. a. (2013):** Plant species identification by using Scale Invariant Feature Transform (SIFT) and Grid Based Colour Moment (GBCM), in: Conference on Open Systems, Nr. 1, S. 226–230.
- Chen, Y./Lin, P./He, Y. (2011):** Velocity representation method for description of contour shape and the classification of weed leaf images, in: Biosystems Engineering, 109. Jg., Nr. 3, S. 186–195.
- Cho, S.-Y. (2012):** Content-based structural recognition for flower image classification, in: IEEE Conference on Industrial Electronics and Applications (ICIEA), Nr. 7, S. 541–546.
- Ding, W./Taylor, G. (2016):** Automatic moth detection from trap images for pest management, in: Computers and Electronics in Agriculture, Nr. 123, S. 17–28.

- Du, J.-X./Wang, X.-F./Zhang, G.-J. (2007):** Leaf shape based plant species recognition, in: *Applied Mathematics and Computation*, 185. Jg., Nr. 2, S. 883–893.
- Du, J.-X./Zhai, C.-M./Wang, Q.-P. (2013):** Recognition of plant leaf image based on fractal dimension features, in: *Neurocomputing*, Nr. 116, S. 150–156.
- Elhariri, E./El-Bendary, N./Hassanien, A. E. (2014):** Plant classification system based on leaf features, in: *International Conference on Computer Engineering Systems*, Nr. 9, S. 271–276.
- Favret, C./Sieracki, J. M. (2016):** Machine vision automated species identification scaled towards production levels, in: *Systematic Entomology*, 41. Jg., Nr. 1, S. 133–143.
- Feng, L./Bhanu, B. (2013):** Automated identification and retrieval of moth images with semantically related visual attributes on the wings, in: *IEEE International Conference on Image Processing*, Nr. 1, S. 2577–2581.
- Fotopoulou, F. u. a. (2013):** Advanced leaf image retrieval via Multidimensional Embedding Sequence Similarity (MESS) method, in: *Pattern Analysis and Applications*, 16. Jg., Nr. 3, S. 381–392.
- Ghasab, M. A. J. u. a. (2015):** Feature decision-making ant colony optimization system for an automated recognition of plant species, in: *Expert Systems with Applications*, 42. Jg., Nr. 5, S. 2361–2370.
- Hong, S.-W./Choi, L. (2012):** Automatic recognition of flowers through color and edge based contour detection, in: *International Conference on Image Processing Theory, Tools and Applications (IPTA)*, Nr. 3, S. 141–146.
- Hossain, J./Amin, M. A. (2010):** Leaf shape identification based plant biometrics, in: *International Conference on Computer and Information Technology*, Nr. 13, S. 456–463.
- Hsiao, J.-K. u. a. (2014):** Comparative study of leaf image recognition with a novel learning-based approach, in: *Science and Information Conference*, Nr. 1, S. 389–393.
- Hu, R. u. a. (2012):** Multiscale distance matrix for fast plant leaf recognition, in: *IEEE Transactions on Image Processing*, 21. Jg., Nr. 11, S. 4667–4672.
- James Nesaratnam, R./BalaMurugan, C. (2015):** Identifying leaf in a natural image using morphological characters, in: *International Conference on Innovations in Information, Embedded and Communication systems*, Nr. 1, S. 1–5.
- Jia, Y. u. a. (2014):** Caffe: Convolutional Architecture for Fast Feature Embedding, in: *ACM international conference on Multimedia*, Nr. 22, S. 675–678.
- Jobin, A./Nair, M. S./Tatavarti, R. (2012):** Plant Identification based on Fractal Refinement Technique (FRT), in: *Procedia Technology*, Nr. 6, S. 171–178.
- Kang, S.-H./Cho, J.-H./Lee, S.-H. (2014):** Identification of butterfly based on their shapes when viewed from different angles using an artificial neural network, in: *Journal of Asia-Pacific Entomology*, 17. Jg., Nr. 2, S. 143–149.
- Kang, S.-H./Jeon, W./Lee, S.-H. (2012):** Butterfly species identification by branch length similarity entropy, in: *Journal of Asia-Pacific Entomology*, 15. Jg., Nr. 3, S. 437–441.
- Kang, S.-H./Song, S.-H./Lee, S.-H. (2012):** Identification of butterfly species with a single neural network system, in: *Journal of Asia-Pacific Entomology*, 15. Jg., Nr. 3, S. 431–435.
- Kaya, Y./Kayci, L./Tekin, R. (2013):** A computer vision system for the automatic identifi-

cation of butterfly species via Gabor-filter-based texture features and extreme learning machine: GF + ELM, in: TEM Journal, 2. Jg., Nr. 1, S. 13–20.

Kaya, Y./Kayci, L. (2014): Application of artificial neural network for automatic detection of butterfly species using color and texture features, in: The Visual Computer, 30. Jg., Nr. 1, S. 71–79.

Kaya, Y. u. a. (2013): Evaluation of texture features for automatic detecting butterfly species using extreme learning machine, in: Journal of Experimental & Theoretical Artificial Intelligence, 26. Jg., Nr. 2, S. 267–281.

Kaya, Y./Kayci, L./Uyar, M. (2015): Automatic identification of butterfly species based on local binary patterns and artificial neural network, in: Applied Soft Computing, Nr. 28, S. 132–137.

Kayci, L./Kaya, Y. (2014): A vision system for automatic identification of butterfly species using a grey-level co-occurrence matrix and multinomial logistic regression, in: Zoology in the Middle East, 60. Jg., Nr. 1, S. 57–64.

Laga, H. u. a. (2012): A Riemannian Elastic Metric for Shape-Based Plant Leaf Classification, in: 2012 International Conference on Digital Image Computing Techniques and Applications (DICTA), Nr. 1, S. 1–7.

Larese, M. G. u. a. (2014): Multiscale recognition of legume varieties based on leaf venation images, in: Expert Systems with Applications, 41. Jg., Nr. 10, S. 4638–4647.

Larios, N. u. a. (2008): Automated insect identification through concatenated histograms of local appearance features, Feature vector generation and region detection for deformable objects, in: Machine Vision and Applications, 19. Jg., Nr. 2, S. 105–123.

Lavania, S./Matey, P. S. (2014): Leaf recognition using contour based edge detection and SIFT algorithm, in: Computational Intelligence and Computing Research (ICCIC), Nr. 1, S. 1–4.

Lee, S.-H./Kang, S.-H. (2016): Performance enhancement of the branch length similarity entropy descriptor for shape recognition by introducing critical points, in: Journal of the Korean Physical Society, 69. Jg., Nr. 7, S. 1254–1262.

Le-Qing, Z./Zhen, Z. (2012): Automatic insect classification based on local mean colour feature and Supported Vector Machines, in: Oriental Insects, 46. Jg., Nr. 3-4, S. 260–269.

Ling, H./Jacobs, D. W. (2007): Shape classification using the inner-distance, in: Transactions on Pattern Analysis and Machineintelligence, 29. Jg., Nr. 2, S. 286–299.

Liu, H. u. a. (2014): Leaf Species Classification Based on a Botanical Shape Sub-classifier Strategy, in: Pattern Recognition, Nr. 22, S. 1496–1501.

Lu, H. u. a. (2016): Toward Good Practices for Fine-Grained Maize Cultivar Identification With Filter-Specific Convolutional Activations, in: Transactions on Automation Science and Engineering, Nr. 99, S. 1–13.

Mayo, M./Watson, A. T. (2007): Automatic species identification of live moths, in: Knowledge-Based Systems, 20. Jg., Nr. 2, S. 195–202.

Mouine, S./Yahiaoui, I./Verroust-Blondet, A. (2012): Advanced shape context for plant species identification using leaf image retrieval, in: Proceedings of the 2nd ACM International

Conference on Multimedia Retrieval, Nr. 49, S. 1–8.

Mouine, S./Yahiaoui, I./Verroust-Blondet, A. (2013): A shape-based approach for leaf classification using multiscaletriangular representation, in: Proceedings of the 3rd ACM conference on International conference on multimedia retrieval, Nr. 1, S. 127–134.

Mouine, S./Yahiaoui, I./Verroust-Blondet, A. (2013): Plant species recognition using spatial correlation between the leaf margin and the leaf salient points, in: International Conference on Image Processing, Nr. 20, S. 1466–1470.

Mzoughi, O. u. a. (2013): Advanced tree species identification using multiple leaf parts image queries, in: 20th IEEE International Conference on Image Processing, Nr. 1, S. 3967–3971.

Mzoughi, O. u. a. (2016): Semantic-based automatic structuring of leaf images for advanced plant species identification, in: Multimedia Tools and Applications, 75. Jg., Nr. 3, S. 1615–1646.

Nguyen, Q.-K./Le, T.-L./Pham, N.-H. (2013): Leaf based plant identification system for Android using SURF features in combination with Bag of Words model and supervised learning, in: International Conference on Advanced Technologies for Communications, Nr. 1, S. 404–407.

Novotný, P./Suk, T. (2013): Leaf recognition of woody species in Central Europe, in: Biosystems Engineering, 115. Jg., Nr. 4, S. 444–452.

Pauwels, E. J./Zeeuw, P. M. de/Rangelova, E. B. (2009): Computer-assisted tree taxonomy by automated image recognition, in: Engineering Applications of Artificial Intelligence, 22. Jg., Nr. 1, S. 26–31.

Pham, N.-H. u. a. (2013): Computer aided plant identification system, in: International Conference on Computing, Management and Telecommunications (ComManTel), Nr. 1, S. 134–139.

Prasad, S./Peddoju, S. K./Ghosh, D. (2013): Mobile plant species classification, A low computational approach, in: IEEE Second International Conference on Image Information Processing, Nr. 2, S. 405–410.

Raghavendra, R./Venkatesh, S. K. (2011): Local Gabor Phase Quantization Scheme for Robust Leaf Classification, in: Third National Conference on Computer Vision, Pattern Recognition, Image Processing and Graphics, Nr. 3, S. 211–214.

Santana, F. S. u. a. (2014): A reference process for automating bee species identification based on wing images and digital image processing, in: Ecological Informatics, Nr. 24, S. 248–260.

Silveira, M./Monteiro, A. (2009): Automatic recognition and measurement of butterfly eyespot patterns, in: Bio Systems, 95. Jg., Nr. 2, S. 130–136.

Spampinato, C. u. a. (2010): Automatic fish classification for underwater species behavior understanding, in: Proceedings of the first ACM international workshop on Analysis and retrieval of tracked events and motion in imagery streams, Nr. 1, S. 45–50.

Tek, F. B. u. a. (2014): Robust localization and identification of African clawed frogs in digital images, in: Ecological Informatics, Nr. 23, S. 3–12.

Thipayang, N./Benjamas, N./Hanboonsong, Y. (2013): Improving feature extraction using Part Separating algorithm, Case study forinsect identification of Order Lepidoptera, in: International Conference on Knowledge and Smart Technology, Nr. 6, S. 75–80.

van Nguyen, H./Porikli, F. (2013): Support vector shape, A classifier-based shape representation, in: Transactions on Pattern Analysis and Machine Intelligence, 35. Jg., Nr. 4, S. 970–982.

- Wang, B. u. a. (2013):** Mobile plant leaf identification using smart-phones, in: IEEE International Conference on Image Processing, Nr. 1, S. 4417–4421.
- Wang, B. u. a. (2015):** MARCH, Multiscale-arch-height description for mobile retrieval of leaf images, in: Information Sciences, Nr. 302, S. 132–148.
- Wang, J. u. a. (2012):** The identification of butterfly families using content-based image retrieval, in: Biosystem Engineering, 111. Jg., Nr. 1, S. 24–32.
- Wang, J. u. a. (2012):** A new automatic identification system of insect images at the order level, in: Knowledge-Based Systems, Nr. 33, S. 102–110.
- Wang, X.-F. u. a. (2008):** Classification of plant leaf images with complicated background, in: Applied Mathematics and Computation, 205. Jg., Nr. 2, S. 916–926.
- Wang, X./Liang, J./Guo, F. (2014):** Feature extraction algorithm based on dual-scale decomposition and local binary descriptors for plant leaf recognition, in: Digital Signal Processing, Nr. 34, S. 101–107.
- Wang, Z. u. a. (2014):** Plant recognition based on intersecting cortical model, in: International Joint Conference on Neural Networks, Nr. 1, S. 975–980.
- Wang, Z. u. a. (2011):** Leaf Image Classification with Shape Context and SIFT Descriptors, in: International Conference on Digital Image Computing: Techniques and Applications, Nr. 1, S. 650–654.
- Wang, Z.-Z./Yong, J.-H. (2008):** Texture analysis and classification with linear regression model based on wavelet transform, in: Transactions on Image Processing, 17. Jg., Nr. 8, S. 1421–1430.
- Watcharabutsarakham, S. u.a. (2012):** Leaf classification using structure features and support vector machines, in: International conference on new trends in information science and service science and data mining, Nr. 6, S. 697–700.
- Watson, A. T./O'Neill, M. A./Kitching, I. J. (2004):** Automated identification of live moths (Macrolepidoptera) using digital automated identification System (DAISY), in: Systematics and Biodiversity, 1. Jg., Nr. 3, S. 287–300.
- Wen, C./Guyer, D. (2012):** Image-based orchard insect automated identification and classification method, in: Computers and Electronics in Agriculture, Nr. 89, S. 110–115.
- Wen, C./Guyer, D. E./Li, W. (2009):** Local feature-based identification and classification for orchard insects, in: Biosystems Engineering, 104. Jg., Nr. 3, S. 299–307.
- Wu, S. G. u. a. (2007):** A Leaf Recognition Algorithm for Plant Classification Using Probabilistic Neural Network, in: IEEE International Symposium on Signal Processing and Information Technology, Nr. 1, S. 11–16.
- Yaakob, S. N./Jain, L. (2012):** An insect classification analysis based on shape features using quality threshold ARTMAP and moment invariant, in: Applied Intelligence, 37. Jg., Nr. 1, S. 12–30.
- Yahiaoui, I./Mzoughi, O./Boujemaa, N. (2012):** Leaf Shape Descriptor for Tree Species Identification, in: Multimedia and Expo, Nr. 1, S. 254–259.
- Yanikoglu, B./Aptoula, E./Tirkaz, C. (2014):** Automatic plant identification from photographs, in: Machine Vision and Applications, 25. Jg., Nr. 6, S. 1369–1383.

- Zawbaa, H. M. u. a. (2014):** An automatic flower classification approach using machine learning algorithms, in: International Conference on Advances in Computing, Communications and Informatics, Nr. 1, S. 895–901.
- Zhai, C.-M./Du, J.-X. (2008):** Applying extreme learning machine to plant species identification, in: International Conference on Information and Automation, Nr. 1, S. 879–884.
- Zhang, C. u. a. (2015):** A Convolutional Neural Network for Leaves Recognition Using Data Augmentation, in: IEEE International Conference on Computer and Information Technology; Ubiquitous Computing and Communications; Dependable, Autonomic and Secure Computing; Pervasive Intelligence and Computing, Nr. 1, S. 2143–2150.
- Zhang, L. u. a. (2008):** Plant Species Identification Based on Neural Network, in: International Conference on Natural Computation, Nr. 4, S. 90–94.
- Zhang, S./Feng, Y. (2010):** Plant leaf classification using plant leaves based on rough set, in: Proceedings of ICCASM 2010, Nr. 15, S. 521–525.
- Zhang, S./Lei, Y.-K. (2011):** Modified locally linear discriminant embedding for plant leaf recognition, in: Neurocomputing, 74. Jg., Nr. 14-15, S. 2284–2290.
- Zhao, C. u. a. (2015):** Plant identification using leaf shapes—A pattern counting approach, in: Pattern Recognition, 48. Jg., Nr. 10, S. 3203–3215.
- Zhu, L./Zhang, Z./Zhang, D. (2015):** Recognising lepidopteran images based on locality-constrained linear coding and SVM, in: Oriental Insects, 49. Jg., Nr. 1-2, S. 36–46.
- Zulkifli, Z./Saad, P./Mohtar, I. A. (2011):** Plant leaf identification using moment invariants & General Regression Neural Network, in: Proceedings of HIS, Nr. 1, S. 430–435.

Quellenverzeichnisse

Literaturverzeichnis

- Alpaydin, E. (2014):** *Introduction to machine learning*. 3. Auflage. Cambridge: MIT press. ISBN: 9780262028189.
- Apriyanti, D. H./Arymurthy, A. M./Handoko, L. T. (2013):** „Identification of orchid species using content-based flower image retrieval“. In: *International Conference on Computer, Control, Informatics and Its Applications* Nr. 1, S. 53–57. DOI: 10.1109/IC3INA.2013.6819148.
- Bothe, H.-H. (1993):** „Mustererkennung“. In: *Fuzzy Logic*. Berlin, Heidelberg: Springer, S. 174–191.
- Döring, N./Bortz, J. (2016):** *Forschungsmethoden und Evaluation in den Sozial- und Humanwissenschaften*. 5. Auflage. Springer-Lehrbuch. Berlin/Heidelberg: Springer. ISBN: 978-3-642-41088-8. DOI: 10.1007/978-3-642-41089-5. URL: <http://dx.doi.org/10.1007/978-3-642-41089-5>.
- Du, J.-X./Wang, X.-F./Zhang, G.-J. (2007):** „Leaf shape based plant species recognition“. In: *Applied Mathematics and Computation* 185.Nr. 2, S. 883–893. ISSN: 00963003. DOI: 10.1016/j.amc.2006.07.072.
- Ertel, W. (2016):** *Grundkurs Künstliche Intelligenz. Eine praxisorientierte Einführung*. 4. Auflage. Wiesbaden: Springer Vieweg. ISBN: 978-3-658-13548-5. DOI: 10.1007/978-3-658-13549-2.
- Everingham, M. u. a. (2010):** „The pascal visual object classes (voc) challenge“. In: *International journal of computer vision* 88. Jg., Nr. 2, S. 303–338.
- Feng, L./Bhanu, B. (2013):** „Automated identification and retrieval of moth images with semantically related visual attributes on the wings“. In: *IEEE International Conference on Image Processing* Nr. 1, S. 2577–2581. DOI: 10.1109/ICIP.2013.6738531.
- Gonzalez, R. C./Woods, R. E. (2008):** *Digital image processing*. 3. Auflage. Upper Saddle River: Pearson/Prentice Hall. ISBN: 978-0131687288.
- Hastie, T./Tibshirani, R./Friedman, J. (2009):** „The Elements of Statistical Learning“. In: *Springer series in statistics*. New York: Springer, S. 337–387. DOI: 10.1007/978-0-387-84858-7.
- Huang, G.-B./Zhu, Q.-Y./Siew, C.-K. (2006):** „Extreme learning machine: theory and applications“. In: *Neurocomputing* 70. Jg., Nr. 1-3, S. 489–501.
- James Nesaratnam, R./BalaMurugan, C. (2015):** „Identifying leaf in a natural image using morphological characters“. In: *International Conference on Innovations in Information, Embedded and Communication systems* Nr. 1, S. 1–5. DOI: 10.1109/ICIIECS.2015.7193115.
- Jungclaussen, H. (2013):** *Kausale Informatik: Einführung in die Lehre vom aktiven sprachlichen Modellieren durch Mensch und Computer*. Wiesbaden: Deutscher Universitätsverlag.

- Kang, S.-H./Cho, J.-H./Lee, S.-H. (2014):** „Identification of butterfly based on their shapes when viewed from different angles using an artificial neural network“. In: *Journal of Asia-Pacific Entomology* 17. Jg., Nr. 2, S. 143–149. ISSN: 12268615. DOI: 10.1016/j.aspen.2013.12.004.
- Kang, S.-H./Jeon, W./Lee, S.-H. (2012):** „Butterfly species identification by branch length similarity entropy“. In: *Journal of Asia-Pacific Entomology* 15. Jg., Nr. 3, S. 437–441. ISSN: 12268615. DOI: 10.1016/j.aspen.2012.05.005.
- Kang, S.-H./Song, S.-H./Lee, S.-H. (2012):** „Identification of butterfly species with a single neural network system“. In: *Journal of Asia-Pacific Entomology* 15. Jg., Nr. 3, S. 431–435. ISSN: 12268615. DOI: 10.1016/j.aspen.2012.03.006.
- Kaya, Y./Kayci, L. (2014):** „Application of artificial neural network for automatic detection of butterfly species using color and texture features“. In: *The Visual Computer* 30. Jg., Nr. 1, S. 71–79. DOI: 10.1007/s00371-013-0782-8.
- Kaya, Y./Kayci, L./Tekin, R. u. a. (2013):** „Evaluation of texture features for automatic detecting butterfly species using extreme learning machine“. In: *Journal of Experimental & Theoretical Artificial Intelligence* 26. Jg., Nr. 2, S. 267–281. DOI: 10.1080/0952813X.2013.861875.
- Kaya, Y./Kayci, L./Uyar, M. (2015):** „Automatic identification of butterfly species based on local binary patterns and artificial neural network“. In: *Applied Soft Computing* Nr. 28, S. 132–137. ISSN: 15684946. DOI: 10.1016/j.asoc.2014.11.046.
- Kayci, L./Kaya, Y. (2014):** „A vision system for automatic identification of butterfly species using a grey-level co-occurrence matrix and multinomial logistic regression“. In: *Zoology in the Middle East* 60. Jg., Nr. 1, S. 57–64. DOI: 10.1080/09397140.2014.892340.
- Kitchenham, B. (2004):** „Procedures for Performing Systematic Reviews“. Joint Technical Report. Eversleigh: Keele University. URL: <http://www.inf.ufsc.br/~aldo.vw/kitchenham.pdf>.
- Laga, H. u. a. (2012):** „A Riemannian Elastic Metric for Shape-Based Plant Leaf Classification“. In: *2012 International Conference on Digital Image Computing Techniques and Applications (DICTA)* Nr. 1, S. 1–7. DOI: 10.1109/DICTA.2012.6411702.
- Larios, N. u. a. (2008):** „Automated insect identification through concatenated histograms of local appearance features: Feature vector generation and region detection for deformable objects“. In: *Machine Vision and Applications* 19. Jg., Nr. 2, S. 105–123. ISSN: 0932-8092. DOI: 10.1007/s00138-007-0086-y.
- Lecun, Y. u. a. (1998):** „Gradient-based learning applied to document recognition“. In: *Proceedings of the IEEE* 86. Jg., Nr. 11, S. 2278–2324. ISSN: 0018-9219. DOI: 10.1109/5.726791.
- Lee, S.-H./Kang, S.-H. (2016):** „Performance enhancement of the branch length similarity entropy descriptor for shape recognition by introducing critical points“. In: *Journal of the Korean Physical Society* 69. Jg., Nr. 7, S. 1254–1262. DOI: 10.3938/jkps.69.1254.
- LISA lab., Hrsg. (o. J.a):** *Convolutional Neural Networks (LeNet)*. URL: <http://deeplearning.net/tutorial/lenet.html> (Abruf: 20.01.2018).

- LISA lab.**, Hrsg. (o. J.b): *Multilayer Perceptron*. URL: <http://deeplearning.net/tutorial/mlp.html> (Abruf: 24.01.2018).
- Manjunath, B. S. u. a. (2001)**: „Color and texture descriptors“. In: *IEEE Transactions on Circuits and Systems for Video Technology* 11. Jg., Nr. 6, S. 703–715. DOI: 10.1109/76.927424.
- Manning, C. D./Raghavan, P./Schütze, H. (2008)**: *Introduction to information retrieval*. New York: Cambridge University Press. ISBN: 978-0-521-86571-5.
- Martinez, A. M./Kak, A. C. (2001)**: „PCA versus LDA“. In: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 23. Jg., Nr. 2, S. 228–233. ISSN: 0162-8828. DOI: 10.1109/34.908974.
- Mouine, S./Yahiaoui, I./Verroust-Blondet, A. (2012)**: „Advanced shape context for plant species identification using leaf image retrieval“. In: *Proceedings of the 2nd ACM International Conference on Multimedia Retrieval* Nr. 49, S. 1–8. DOI: 10.1145/2324796.2324853.
- **(2013a)**: „A shape-based approach for leaf classification using multiscaletriangular representation“. In: *Proceedings of the 3rd ACM conference on International conference on multimedia retrieval* Nr. 1, S. 127–134. DOI: 10.1145/2461466.2461489.
- **(2013b)**: „Plant species recognition using spatial correlation between the leaf margin and the leaf salient points“. In: *International Conference on Image Processing* Nr. 20, S. 1466–1470. DOI: 10.1109/ICIP.2013.6738301.
- Mzoughi, O. u. a. (2013)**: „Advanced tree species identification using multiple leaf parts image queries“. In: *20th IEEE International Conference on Image Processing* Nr. 1, S. 3967–3971. DOI: 10.1109/ICIP.2013.6738817.
- Niu, J. u. a. (2016)**: „Global Research on Artificial Intelligence from 1990–2014: Spatially-Explicit Bibliometric Analysis“. In: *ISPRS International Journal of Geo-Information* 5. Jg., Nr. 5, S. 1–19. DOI: 10.3390/ijgi5050066. URL: <http://www.mdpi.com/2220-9964/5/5/66>.
- Pautasso, M. (2013)**: „Ten Simple Rules for Writing a Literature Review“. In: *PLOS Computational Biology* 9. Jg., Nr. 7, S. 1–4. URL: <http://journals.plos.org/ploscompbiol/article?id=10.1371/journal.pcbi.1003149#s2>.
- Pauwels, E. J./de Zeeuw, P. M./Rangelova, E. B. (2009)**: „Computer-assisted tree taxonomy by automated image recognition“. In: *Engineering Applications of Artificial Intelligence* 22. Jg., Nr. 1, S. 26–31. ISSN: 09521976. DOI: 10.1016/j.engappai.2008.04.017.
- Sammut, C./Webb, G. I. (2011)**: „Neural Networks“. In: *Encyclopedia of Machine Learning*. Boston: Springer. ISBN: 978-0-387-30164-8. DOI: 10.1007/978-0-387-30164-8_586. URL: https://doi.org/10.1007/978-0-387-30164-8_586.
- Sezgin, M./Sankur, B. (2004)**: „Survey over image thresholding techniques and quantitative performance evaluation“. In: *Journal of Electronic imaging* 13. Jg., Nr. 1, S. 146–166.
- Silveira, M./Monteiro, A. (2009)**: „Automatic recognition and measurement of butterfly eyespot patterns“. In: *Bio Systems* 95. Jg., Nr. 2, S. 130–136. ISSN: 1872-8324. DOI: 10.1016/j.biosystems.2008.09.004.
- Suthaharan, S. (2016)**: *Machine learning models and algorithms for big data classification*. Boston: Springer.

- Thipayang, N./Benjamas, N./Hanboonsong, Y. (2013):** „Improving feature extraction using Part Separating algorithm: Case study for insect identification of Order Lepidoptera“. In: *International Conference on Knowledge and Smart Technology* Nr. 6, S. 75–80. DOI: 10.1109/KST.2014.6775397.
- Trinkwalder, A. (2016):** „Netzgespinste, Die Mathematik neuronaler Netze: einfache Mechanismen, komplexe Konstruktion“. In: *c't* 16. Jg., Nr. 6, S. 130.
- Wäldchen, J./Mäder, P. (2017):** „Plant Species Identification Using Computer Vision Techniques: A Systematic Literature Review“. In: *Archives of Computational Methods in Engineering* 24. Jg., Nr. 4, S. 509–545. ISSN: 1134-3060. DOI: 10.1007/s11831-016-9206-z.
- Wang, B. u. a. (2015):** „MARCH: Multiscale-arch-height description for mobile retrieval of leaf images“. In: *Information Sciences* Nr. 302, S. 132–148. DOI: 10.1016/j.ins.2014.07.028.
- Wang, J. u. a. (2012):** „A new automatic identification system of insect images at the order level“. In: *Knowledge-Based Systems* Nr. 33, S. 102–110. ISSN: 09507051. DOI: 10.1016/j.knosys.2012.03.014.
- Wang, Z. u. a. (2014):** „Plant recognition based on intersecting cortical model“. In: *International Joint Conference on Neural Networks* Nr. 1, S. 975–980. DOI: 10.1109/IJCNN.2014.6889656.
- Wen, C./Guyer, D. (2012):** „Image-based orchard insect automated identification and classification method“. In: *Computers and Electronics in Agriculture* Nr. 89, S. 110–115. ISSN: 01681699. DOI: 10.1016/j.compag.2012.08.008.
- Wen, C./Guyer, D. E./Li, W. (2009):** „Local feature-based identification and classification for orchard insects“. In: *Biosystems Engineering* 104. Jg., Nr. 3, S. 299–307. ISSN: 15375110. DOI: 10.1016/j.biosystemseng.2009.07.002.
- Zhu, L./Zhang, Z./Zhang, D. (2015):** „Recognising lepidopteran images based on locality-constrained linear coding and SVM“. In: *Oriental Insects* 49. Jg., Nr. 1-2, S. 36–46. ISSN: 0030-5316. DOI: 10.1080/00305316.2015.1081641.

Erklärung

Wir versichern hiermit, dass wir unsere Seminararbeit mit dem Thema: *Visuelle Artenklassifizierung durch maschinelles Lernen. Eine systematische Literaturrecherche* selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt haben.

Wir versichern zudem, dass die eingereichte elektronische Fassung mit der gedruckten Fassung übereinstimmt.

(Ort, Datum)

(Dennis Adeler)

(Ort, Datum)

(Tobias Eberle)

(Ort, Datum)

(Andreas Frölich)

(Ort, Datum)

(Martha Klimek)

(Ort, Datum)

(Manuel Kopittke)

(Ort, Datum)

(Lisa Martiny)

(Ort, Datum)

(Mike Nolden)